

VEHICLE RE-IDENTIFICATION

*Đồ án môn học: Thị giác máy tính

1st Chung Tín Đạt
MSSV: 23122024

2nd Nguyễn Đăng Khôi
MSSV: 23122037

Tóm tắt nội dung—Báo cáo trình bày bài toán Vehicle Re-Identification (Vehicle ReID), trong đó hệ thống cần truy xuất và tái nhận diện cùng một phương tiện qua nhiều camera khác nhau. Nội dung tập trung vào bối cảnh, phát biểu bài toán, quy trình xử lý, dữ liệu VeRi-776, kiến trúc baseline dựa trên ResNet50, chiến thuật huấn luyện bằng ID Loss và Triplet Loss, cùng các chỉ số đánh giá như CMC và mAP. Báo cáo cũng tổng hợp kết quả thực nghiệm ban đầu và đề xuất các hướng cải tiến cho giai đoạn tiếp theo.

Index Terms—Vehicle Re-Identification, ResNet50, Bag of Tricks, Global Average Pooling, Embedding Space.

I. GIỚI THIỆU

Sự phát triển của mạng lưới camera giám sát giao thông đòi hỏi các giải pháp tự động hóa để tìm kiếm và theo dõi phương tiện. Bài toán Vehicle Re-Identification (Vehicle ReID) giải quyết vấn đề xác định lại một phương tiện đã xuất hiện ở một camera tại các vị trí camera khác trong cùng hệ thống.

So với các bài toán image classification thông thường, Vehicle ReID có những yêu cầu kỹ thuật phức tạp hơn. Đặc tính quan trọng nhất là mô hình phải giải quyết bài toán open-set retrieval, nghĩa là các ID phương tiện trong tập test hoàn toàn khác biệt và chưa từng xuất hiện trong tập train. Mục tiêu của mạng là học cách biểu diễn một embedding space tổng quát, sao cho khoảng cách giữa các vector đặc trưng phản ánh chính xác mức độ tương đồng hình ảnh.

Dựa trên đặc điểm thực tế của tập dữ liệu VeRi-776 (Hình 1), bài toán phải xử lý ba thách thức chính:

- Intra-class variance:** Hình ảnh của cùng một phương tiện thay đổi đáng kể do sự thay đổi về viewpoint và điều kiện ánh sáng.
- Inter-class similarity:** Các phương tiện có ID khác nhau nhưng lại rất giống nhau về ngoại hình tổng thể (cùng dòng, cùng màu sơn).
- Occlusion:** Phương tiện thường xuyên bị che khuất một phần bởi các yếu tố môi trường.

MỘT SỐ MẪU ẢNH TRONG TẬP VERI-776 (MINH HỌA GÓC CHỤP & ẢNH SÁNG)



Hình 1. Minh họa các thách thức nhận diện trên tập dữ liệu VeRi-776, bao gồm sự thay đổi góc chụp và sự tương đồng về ngoại hình giữa các phương tiện khác ID.

II. PHÁT BIỂU BÀI TOÁN

A. Mục tiêu của Vehicle Re-Identification

Vehicle ReID là bài toán xác định sự trùng khớp của một phương tiện cụ thể qua các ảnh chụp từ các camera khác nhau. Khác với bài toán image classification, ReID tập trung vào việc học một embedding space (không gian nhúng) sao cho các ảnh cùng ID của một xe có khoảng cách gần nhau và các xe khác ID có khoảng cách xa nhau.

B. Đầu vào và đầu ra

- Đầu vào:** Tập hợp các ảnh phương tiện được trích xuất từ các góc quay camera khác nhau. Trong giai đoạn huấn luyện, mỗi ảnh đi kèm với nhãn ID phương tiện và Camera ID.
- Đầu ra:** Một vector đặc trưng (embedding vector) đại diện cho nội dung hình ảnh của phương tiện. Hệ thống trả về danh sách các ảnh trong cơ sở dữ liệu được sắp xếp theo mức độ tương đồng với ảnh truy vấn.

C. Các giai đoạn xử lý

Quy trình thực hiện bài toán được chia làm hai giai đoạn chính:

- Giai đoạn Offline:** Xây dựng cơ sở dữ liệu đặc trưng.
 - Huấn luyện:** Gọi I là ảnh đầu vào, mô hình $f(I, \theta)$ ánh xạ ảnh thành vector đặc trưng $E \in \mathbb{R}^d$, với d là số chiều của không gian embedding.
 - Trích xuất Gallery:** Sau khi huấn luyện, toàn bộ ảnh trong tập Gallery được đưa qua mô hình để trích xuất đặc trưng và lưu trữ thành tập $G = \{E_1, E_2, \dots, E_N\}$.
- Giai đoạn Online:** Thực hiện truy xuất (Retrieval).
 - Sinh vector truy vấn:** Ảnh query I_q được đưa qua mô hình để tạo vector $E_q = f(I_q, \theta)$.
 - Tính toán độ tương đồng:** Sử dụng metric Cosine Similarity để đo lường mức độ giống nhau giữa E_q và các E_i trong Gallery:

$$\text{sim}(E_q, E_i) = \frac{E_q \cdot E_i}{\|E_q\|_2 \cdot \|E_i\|_2} \quad (1)$$

- Sắp xếp kết quả:** Hệ thống sắp xếp các ảnh E_i theo giá trị sim giảm dần để đưa ra kết quả Rank-k.

III. PHƯƠNG PHÁP ĐỀ XUẤT

A. Tiền xử lý và Data Augmentation

Trước khi đưa vào mô hình, toàn bộ ảnh phương tiện được chuẩn hóa về cùng một định dạng đầu vào nhằm đảm bảo tính ổn định trong quá trình huấn luyện và đánh giá. Các ảnh được đọc ở hệ màu RGB, sau đó thay đổi kích thước về (256, 256) để đồng nhất kích thước tensor và hỗ trợ xử lý theo batch trong PyTorch.

Vì backbone ResNet50 được khởi tạo từ trọng số huấn luyện trước trên ImageNet, ảnh đầu vào cần được chuẩn hóa theo thống kê của ImageNet. Cụ thể, mỗi kênh màu được chuẩn hóa với $mean = [0.485, 0.456, 0.406]$ và $std = [0.229, 0.224, 0.225]$. Bước này giúp phân phối dữ liệu đầu vào tương thích hơn với các đặc trưng mà backbone đã học trước, từ đó cải thiện tốc độ hội tụ và khả năng tổng quát hóa của mô hình.

Trong giai đoạn huấn luyện, nhóm áp dụng các kỹ thuật tăng cường dữ liệu để mô phỏng những biến thiên thường gặp trong hệ thống camera thực tế, bao gồm thay đổi góc nhìn, ánh sáng, độ tương phản và che khuất một phần phương tiện. Các phép biến đổi chính gồm:

- **Lật ngang ngẫu nhiên:** mô phỏng sự thay đổi hướng di chuyển hoặc vị trí đặt camera.
- **Điều chỉnh độ sáng và độ tương phản:** tăng khả năng thích nghi với các điều kiện chiếu sáng khác nhau như ngày, đêm hoặc bóng râm.
- **Biến đổi hình học nhẹ:** xén hoặc làm nghiêng ảnh để giảm phụ thuộc vào vị trí chính xác của phương tiện trong khung hình.
- **Che khuất ngẫu nhiên (Random Erasing):** tạo các vùng bị che trên ảnh nhằm giúp mô hình học đặc trưng bền vững hơn khi phương tiện bị vật cản hoặc phương tiện khác che một phần.

Đối với tập kiểm thử và tập query, nhóm không áp dụng các phép tăng cường ngẫu nhiên mà chỉ thực hiện resize và chuẩn hóa. Cách xử lý này đảm bảo quá trình đánh giá phản ánh đúng năng lực truy xuất của mô hình trên dữ liệu gốc, đồng thời tránh làm thay đổi nội dung ảnh truy vấn và gallery.

B. Kiến trúc mạng (Network Architecture)

Nhóm thực hiện triển khai song song hai mô hình baseline:

- Mô hình baseline của nhóm: Kiến trúc đề xuất như ??.
- Mô hình *ReID Strong Baseline*¹

Mục tiêu là so sánh hiệu quả của baseline do nhóm đề xuất khi chưa tối ưu với baseline sử dụng kỹ thuật Bag of Tricks. Sau đó ở giai đoạn 2, nhóm sẽ tiến hành áp dụng CBAM (Convolutional Block Attention Module), thông tin metadata camera với cả hai mô hình và đánh giá hiệu quả cải thiện.

Kiến trúc baseline của nhóm được xây dựng theo hướng học đặc trưng sâu cho bài toán truy xuất phương tiện. Thay vì chỉ dự đoán nhãn ID như bài toán phân loại thông thường, mô hình cần sinh ra một vector embedding có khả năng biểu

diễn ổn định cùng một phương tiện dưới nhiều góc nhìn và điều kiện camera khác nhau.

Thành phần trích xuất đặc trưng chính của mô hình là ResNet50 được khởi tạo bằng trọng số huấn luyện trước trên ImageNet. Việc sử dụng backbone đã được tiền huấn luyện giúp mô hình tận dụng các đặc trưng thị giác tổng quát như cạnh, hình khối, màu sắc và cấu trúc vật thể. Để phù hợp hơn với bài toán ReID, nhóm thay đổi stride của khối tích chập cuối từ 2 xuống 1. Điều chỉnh này giúp giữ lại bản đồ đặc trưng có độ phân giải không gian cao hơn, qua đó hạn chế mất mát các chi tiết nhỏ nhưng quan trọng của phương tiện như đèn xe, logo, biển số hoặc đường nét thân xe.

Sau khi ảnh đi qua backbone, mô hình thu được feature map dạng $F \in \mathbb{R}^{H' \times W' \times C'}$. Feature map này được đưa qua lớp Global Average Pooling để tổng hợp thông tin không gian thành một vector đặc trưng toàn cục:

$$z = GAP(F).$$

Vector z đóng vai trò biểu diễn tổng quát của ảnh phương tiện trước khi được đưa vào các nhánh tối ưu tiếp theo.

Trên vector đặc trưng toàn cục, nhóm sử dụng Batch Normalization để ổn định phân phối đặc trưng và tạo embedding phục vụ truy xuất. Thành phần này tương tự ý tưởng BNNeck trong các mô hình ReID, giúp tách biệt tương đối giữa đặc trưng dùng cho phân loại ID và đặc trưng dùng để tính khoảng cách trong không gian embedding. Trong quá trình suy luận, embedding sau chuẩn hóa được sử dụng để so sánh ảnh query với các ảnh trong gallery bằng các độ đo như cosine similarity hoặc Euclidean distance.

Kiến trúc tổng thể của mô hình gồm các thành phần chính sau:

- 1) **Backbone ResNet50:** trích xuất feature map giàu thông tin từ ảnh đầu vào.
- 2) **Global Average Pooling:** chuyển feature map thành vector đặc trưng toàn cục.
- 3) **Batch Normalization / Embedding Head:** chuẩn hóa đặc trưng và tạo embedding dùng cho truy xuất.
- 4) **Classifier Head:** dự đoán ID phương tiện trong giai đoạn huấn luyện để tối ưu ID Loss.

Với thiết kế này, mô hình vừa học được khả năng phân biệt các ID phương tiện trong tập huấn luyện thông qua classifier head, vừa học được không gian embedding có khả năng tổng quát hóa sang các ID chưa từng xuất hiện trong tập kiểm thử.

C. Hàm mất mát (Loss Functions)

Quá trình huấn luyện sử dụng đa mục tiêu (multi-objective loss) để tối ưu hóa đồng thời khả năng phân loại và khoảng cách embedding:

- 1) **ID Loss (Cross-Entropy với Label Smoothing):** Sử dụng để tối ưu khả năng phân loại ID phương tiện. Label Smoothing được áp dụng để làm giảm hiện tượng overconfident của mô hình, giúp embedding space có tính tổng quát tốt hơn.
- 2) **Triplet Loss:** Sử dụng để tối ưu khoảng cách trong embedding space. Hàm này ép khoảng cách giữa các

¹<https://github.com/michuanhaohao/reid-strong-baseline>

cặp ảnh cùng ID (positive pairs) nhỏ hơn khoảng cách giữa các cặp ảnh khác ID (negative pairs) tối thiểu một giá trị margin $m = 0.3$:

$$L_{triplet} = [d_{pos} - d_{neg} + m]_+ \quad (2)$$

Trong đó d_{pos} và d_{neg} là khoảng cách Euclide tương ứng của các cặp mẫu.

D. Chỉ số đánh giá (Evaluation Metrics)

Hiệu suất của mô hình được đo lường bằng hai metric tiêu chuẩn:

- **Rank-k Accuracy (CMC):** Xác suất ảnh đúng nằm trong top-k kết quả trả về. Rank-1 phản ánh độ chính xác truy xuất cao nhất.
- **mean Average Precision (mAP):** Đánh giá khả năng truy xuất toàn bộ các ảnh đúng của một ID trong cơ sở dữ liệu, phản ánh độ ổn định của mô hình trước các biến đổi về góc chụp và ánh sáng.

IV. THỰC NGHIỆM VÀ KẾT QUẢ

A. Cài đặt thực nghiệm

Quá trình huấn luyện và đánh giá mô hình được thực hiện trên môi trường GPU NVIDIA Tesla T4. Tập dữ liệu VeRi-776 được sử dụng cho toàn bộ các pha huấn luyện và kiểm thử.

Cấu hình hyperparameter được thiết lập như sau:

- **Optimizer:** Sử dụng thuật toán Adam để tối ưu hóa trọng số.
- **Batch size:** Thiết lập ở mức 64. Kỹ thuật Balanced Batch Sampler được áp dụng để đảm bảo mỗi batch chứa đúng 16 ID phương tiện, mỗi ID có 4 ảnh ngẫu nhiên. Đây là yêu cầu kỹ thuật bắt buộc để tạo ra các positive pairs và negative pairs phục vụ cho việc tính toán hàm Triplet Loss.
- **Learning rate:** Mức 3×10^{-5} đối với backbone ResNet50 và 3×10^{-4} đối với embedding layer cùng classifier head.
- **Scheduler:**
 - Với mô hình của nhóm, quá trình huấn luyện kéo dài 15 epoch. Chiến lược warmup learning rate được áp dụng trong 5 epoch đầu để tránh hiện tượng gradient explosion tại classifier head. Sau giai đoạn warmup, learning rate giảm theo dần theo cơ chế cosine decay.
 - Với mô hình *ReID Strong Baseline*, quá trình huấn luyện kéo dài 120 epoch, warmup learning rate được áp dụng trong 10 epoch đầu và sau đó giảm theo cơ chế cosine decay.

B. Kết quả định lượng

Để đánh giá hiệu quả triển khai, nhóm so sánh mô hình baseline tự xây dựng với mô hình *ReID Strong Baseline*. Hai mô hình được đánh giá trên cùng bộ dữ liệu theo các chỉ số mAP và CMC tại Rank-1, Rank-5, Rank-10. Kết quả được tổng hợp trong Bảng I.

Kết quả cho thấy *ReID Strong Baseline* đạt hiệu năng rất cao ở các chỉ số Rank-k, đặc biệt là Rank-1 với 93.30%. Điều này cho thấy mô hình có khả năng đưa ít nhất một ảnh đúng

Bảng I
SO SÁNH KẾT QUẢ GIỮA MÔ HÌNH CỦA NHÓM VÀ REID STRONG BASELINE

Mô hình	mAP	Rank-1	Rank-5	Rank-10
ReID Strong Baseline	74.40%	93.30%	97.40%	98.50%
Baseline của nhóm	80.68%	85.10%	93.05%	96.41%

của cùng phương tiện lên vị trí đầu tiên trong danh sách truy xuất. Nói cách khác, baseline này rất mạnh trong việc tìm kiếm các mẫu “easy positive”, tức là những ảnh cùng ID có góc nhìn, điều kiện ánh sáng hoặc đặc điểm trực quan tương đối gần với ảnh truy vấn.


Tuy nhiên, mAP của *ReID Strong Baseline* chỉ đạt 74.40%, thấp hơn đáng kể so với Rank-1. Khoảng cách này cho thấy mặc dù mô hình thường tìm được một kết quả đúng ở vị trí đầu, nhưng chưa tối ưu trong việc đưa toàn bộ các ảnh đúng của cùng một phương tiện lên các thứ hạng cao. Đây là hạn chế quan trọng trong bài toán Vehicle ReID, vì một phương tiện có thể xuất hiện ở nhiều camera với góc nhìn, độ phân giải, ánh sáng và mức độ che khuất khác nhau. Do đó, mAP phản ánh rõ hơn khả năng truy xuất toàn diện trong điều kiện cross-camera matching.

Đối với mô hình baseline của nhóm, mặc dù mới được huấn luyện trong 15 epoch do hạn chế về thời gian, mô hình đạt mAP 80.68%, cao hơn *ReID Strong Baseline* khoảng 6.28%. Kết quả này cho thấy không gian embedding do mô hình của nhóm học được có khả năng bao phủ nhiều mẫu đúng trong gallery tốt hơn, giúp cải thiện chất lượng truy xuất tổng thể. Nói cách khác, mô hình không chỉ tập trung vào kết quả đúng đầu tiên mà còn có xu hướng đưa nhiều ảnh liên quan hơn vào danh sách xếp hạng.

Ngược lại, các chỉ số Rank-k của mô hình nhóm vẫn thấp hơn *ReID Strong Baseline*. Cụ thể, Rank-1 thấp hơn 8.20%, Rank-5 thấp hơn 4.35% và Rank-10 thấp hơn 2.09%. Điều này cho thấy mô hình của nhóm vẫn chưa đủ mạnh trong việc đẩy kết quả đúng nhất lên các vị trí đầu bảng xếp hạng. Một nguyên nhân có thể đến từ số epoch huấn luyện còn ít, khiến classifier head và embedding chưa hội tụ hoàn toàn. Ngoài ra, baseline của nhóm chưa tích hợp đầy đủ các kỹ thuật tối ưu thường dùng trong ReID như BNNeck nâng cao, hard triplet mining, random erasing tối ưu, warm-up learning rate hoặc re-ranking.

Nhìn chung, kết quả so sánh cho thấy hai mô hình có ưu điểm khác nhau. *ReID Strong Baseline* mạnh hơn ở độ chính xác top-k, phù hợp với kịch bản cần tìm nhanh một kết quả đúng ở các vị trí đầu. Trong khi đó, mô hình của nhóm đạt mAP cao hơn, cho thấy tiềm năng tốt hơn trong việc truy xuất nhiều ảnh đúng của cùng phương tiện trên toàn bộ gallery. Đây là cơ sở để nhóm tiếp tục cải tiến mô hình theo hướng vừa duy trì mAP cao, vừa nâng Rank-1 và các chỉ số CMC bằng các kỹ thuật attention, BNNeck, metadata và chiến thuật huấn luyện tốt hơn.

Sự hội tụ của các chỉ số Rank-k được biểu diễn thông qua đường cong Cumulative Matching Characteristics (CMC) trong Hình 2.



Hình 2. Đường cong CMC biểu diễn độ chính xác Rank-k của mô hình Baseline *ReID Strong Baseline*.

V. PHÂN TÍCH VÀ ĐÁNH GIÁ

Bên cạnh các chỉ số định lượng, việc phân tích các trường hợp false match cung cấp cơ sở kỹ thuật để đánh giá giới hạn của kiến trúc baseline *ReID Strong Baseline* hiện tại. Các đánh giá trên mô hình của nhóm hiện chưa được thực hiện do hạn chế về thời gian.

A. Hiện tượng spatial feature collapse

Quan sát các ảnh trả về tại các thứ hạng cao (Hình 3), mô hình thường xuyên phân loại sai khi ảnh query và ảnh false positive có cùng màu sắc tổng thể và cùng viewpoint, bất chấp các chi tiết nhận dạng khác biệt.


Nguyên nhân kỹ thuật xuất phát từ lớp Global Average Pooling (GAP). Lớp GAP ép flatten một spatial feature map 2D thành một embedding vector 1D, loại bỏ hoàn toàn cấu trúc không gian của đối tượng. Khi đó, các fine-grained details chiếm diện tích nhỏ (như biển số, tem xe) bị hòa tan vào các macro features có diện tích lớn (như màu sơn xe). Sự áp đảo của macro features khiến các embedding vector của hai phương tiện khác ID trở nên đồng nhất.



Hình 3. Kết quả truy xuất định tính. Các trường hợp false match (viền đỏ) cho thấy mô hình bị đánh lừa bởi màu sắc và form xe do mất mát chi tiết không gian.

B. Hạn chế của hàm Triplet Loss

Dựa trên phân bố Cosine Similarity thực tế (Hình 4), khoảng cách đặc trưng giữa các ảnh cùng ID (Intra-class) và khác ID (Inter-class) tồn tại một vùng overlap rất lớn.



Hình 4. Biểu đồ phân bố mật độ (KDE) của độ đo Cosine Similarity cho thấy sự chồng lấn lớn giữa các hard negative samples và positive samples.

Hiện tượng này phản ánh giới hạn toán học của hàm Triplet Loss. Hàm này chỉ thực hiện tối ưu hóa khoảng cách tương đối. Khi khoảng cách giữa positive pair và negative pair đạt đến margin $m = 0.3$, hàm loss bị triệt tiêu và ngừng cung cấp gradient. Trạng thái dừng cập nhật sớm tạo ra vùng overlap trong latent space, khiến mô hình mất khả năng phân tách triệt để các hard negative samples. Kỹ thuật Random Erasing được áp dụng nhưng chưa đủ để giải quyết tận gốc nhược điểm của GAP và margin của Triplet Loss.

C. Kế hoạch cải tiến

Trong giai đoạn 2, nhóm sẽ tập trung hoàn thiện và mở rộng hệ thống Vehicle Re-identification theo các hướng sau:

- **Hoàn thiện kiến trúc mô hình:**
 - Tối ưu backbone ResNet50 hiện tại.
 - Tích hợp cơ chế attention CBAM nhằm tăng khả năng tập trung vào các vùng đặc trưng quan trọng của phương tiện như đèn xe, logo, biển số, hình dạng thân xe.
 - Thử nghiệm các biến thể embedding và BNNeck để cải thiện chất lượng không gian đặc trưng.
- **Khai thác thông tin metadata:**
 - Tích hợp thông tin camera ID, hướng di chuyển, màu sắc và loại xe vào pipeline học đặc trưng.
 - Đánh giá mức độ đóng góp của metadata trong việc giảm nhầm lẫn giữa các phương tiện có ngoại hình tương tự.
- **Đánh giá và phân tích mô hình:**
 - Đánh giá chuyên sâu bằng các chỉ số:
 - * mAP (mean Average Precision)
 - * CMC (Cumulative Matching Characteristic)
 - * Rank-1, Rank-5 và Rank-10 Accuracy
 - Phân tích các trường hợp truy vấn khó:

- * Xe có ngoại hình gần giống nhau
- * Khác biệt ánh sáng và góc nhìn
- * Che khuất hoặc chất lượng ảnh thấp
- So sánh trực quan kết quả retrieval giữa các mô hình.

• **Thực hiện Ablation Study:**

- Đánh giá ảnh hưởng của từng thành phần cải tiến:
 - * CBAM
 - * BNNeck
 - * Label Smoothing
 - * Random Erasing
 - * Metadata
 - * Triplet Loss / Circle Loss
- Phân tích mức độ đóng góp của từng kỹ thuật lên mAP và Rank-1 Accuracy.

VI. KẾT LUẬN VÀ ĐỊNH HƯỚNG PHÁT TRIỂN

A. Kết luận

Báo cáo đã thiết lập và kiểm chứng thành công một hệ thống baseline cho bài toán Vehicle ReID. Việc tích hợp kiến trúc backbone ResNet50 với các module tối ưu như BNNeck và hàm multi-objective loss đã giúp hệ thống đạt hiệu suất mAP 74.40% trên tập dữ liệu VeRi-776. Quá trình đánh giá trực tiếp trên các embedding vector và failure cases đã xác định chính xác nguyên nhân gây suy giảm độ chính xác của mô hình khi xử lý các hard negative samples.

B. Định hướng phát triển

Dựa trên phân tích kỹ thuật, trong giai đoạn tiếp theo, nhóm sẽ tiếp tục tối ưu backbone ResNet50, thử nghiệm các kỹ thuật như CBAM, BNNeck, Label Smoothing, Random Erasing và các biến thể metric loss, bổ sung các đánh giá trên mô hình của nhóm. Bên cạnh đó, nhóm dự kiến khai thác thêm metadata như camera ID, hướng di chuyển, màu sắc và loại xe để giảm nhầm lẫn giữa các phương tiện có ngoại hình tương tự.

Nhóm cũng sẽ thực hiện ablation study để đánh giá đóng góp của từng thành phần cải tiến, đồng thời phân tích trực quan các trường hợp truy vấn khó như thay đổi góc nhìn, ánh sáng, che khuất hoặc chất lượng ảnh thấp.

TÀI LIỆU

- [1] H. Luo, Y. Gu, X. Liao, S. Lai, and W. Jiang, "A strong baseline and batch normalization neck for person re-identification," *IEEE Transactions on Multimedia*, vol. 22, no. 10, pp. 2590-2595, 2019.
- [2] X. Liu, W. Liu, T. Mei, and H. Ma, "A deep learning-based approach to progressive vehicle re-identification for urban surveillance," *European Conference on Computer Vision (ECCV)*, 2016.