

Vehicle Re-Identification

Đồ án môn học: Thị giác máy tính

1st Chung Tín Đạt

MSSV: 23122024

2nd Nguyễn Đăng Khôi

MSSV: 23122037

Khoa Công nghệ Thông tin

Trường Đại học Khoa học Tự nhiên

Đại học Quốc gia Thành phố Hồ Chí Minh

Giảng viên hướng dẫn: TS. Võ Hoài Việt, ThS. Phạm Minh Hoàng

Tóm tắt nội dung—Vehicle Re-Identification (Vehicle ReID) là bài toán truy xuất và tái nhận diện cùng một phương tiện qua nhiều camera không chồng lấn, trong đó mô hình cần học được biểu diễn đặc trưng bền vững trước sự thay đổi về góc nhìn, ánh sáng, độ phân giải và che khuất. Báo cáo này xây dựng một hệ thống Vehicle ReID dựa trên backbone ResNet50, kết hợp BNNeck, hàm mất mát đa mục tiêu gồm ID Loss và Triplet Loss, cùng các cải tiến như Convolutional Block Attention Module (CBAM) và Bag of Tricks (BOT). Bốn cấu hình gồm Baseline, BOT, CBAM và BOT + CBAM được huấn luyện trên VeRi776 và đánh giá trên VeRi776 và VRIC nhằm khảo sát hiệu quả trong cùng miền dữ liệu và khả năng tổng quát hóa sang miền dữ liệu khác. Kết quả thực nghiệm cho thấy BOT cải thiện hiệu quả truy xuất so với Baseline, đạt mAP 66.1% và Rank-1 91.9% trên VeRi776; cấu hình BOT + CBAM đạt kết quả tốt nhất trên VRIC với mAP 26.71% và Rank-1 18.85%. Bên cạnh đánh giá định lượng bằng mAP và CMC Rank-k, báo cáo phân tích phân bố độ tương đồng cosine, các trường hợp false match và kết quả truy xuất minh họa để làm rõ giới hạn của mô hình. Các phân tích cho thấy hệ thống vẫn gặp khó khăn với domain shift, các mẫu dương khó, âm khó và các phương tiện có ngoại quan tương tự. Từ đó, báo cáo đề xuất các hướng phát triển như re-ranking, khai thác metadata và tăng cường đặc trưng cục bộ nhằm cải thiện khả năng triển khai trong môi trường giao thông thực tế.

Index Terms—Vehicle Re-Identification, ResNet50, Bag of Tricks, Global Average Pooling, CBAM, Triplet Loss, Embedding Space.

I. GIỚI THIỆU

A. Tổng quan

Trong những năm gần đây, sự bùng nổ của hạ tầng giao thông đô thị cùng với việc triển khai rộng rãi hệ thống Giao thông Thông minh (Intelligent Transportation Systems - ITS) đã dẫn đến sự tích hợp mạnh mẽ của mạng lưới camera giám sát diện rộng. Lượng dữ liệu video khổng lồ được thu thập hàng ngày tạo ra một thách thức lớn trong việc quản lý, đòi hỏi phải có các giải pháp tự động hóa thông minh thay thế cho phương pháp giám sát thủ công vốn tiêu tốn nhiều nhân lực và kém hiệu quả [1]. Trong bối cảnh đó, bài toán Tái định danh Phương tiện (Vehicle Re-Identification - Vehicle ReID) dần thu hút các nhà nghiên cứu bởi sự phát triển nhanh chóng của các kỹ thuật học sâu, tập trung vào việc xác định xem một phương tiện mục tiêu đã từng xuất hiện ở một camera cụ thể có tái xuất hiện tại các vị trí camera khác trong cùng một

hệ thống giám sát có vùng quan sát không giao thoa (non-overlapping camera network) hay không [1], [2], [3].

Công nghệ này đóng vai trò nền tảng trong hàng loạt ứng dụng thực tế quan trọng, bao gồm [3], [4]:

- An ninh công cộng và điều tra tội phạm:** Hỗ trợ lượng chức năng nhanh chóng truy vết, định vị và xác định lộ trình di chuyển của các phương tiện liên quan đến tai nạn hoặc hành vi vi phạm pháp luật.
- Quản lý và điều tiết giao thông:** Thu thập thông kê lưu lượng, phân tích mật độ di chuyển giữa các khu vực để tối ưu hóa tín hiệu đèn giao thông và giảm thiểu ùn tắc.
- Hệ thống thu phí tự động và bãi xe thông minh:** Tự động kiểm tra chéo, xác thực danh tính phương tiện nhằm ngăn chặn các hành vi gian lận biển số hoặc thẻ xe.

B. Động lực nghiên cứu

Mặc dù chia sẻ một số kỹ thuật nền tảng với bài toán phân loại ảnh (Image Classification) truyền thống, Vehicle ReID sở hữu những đặc thù kỹ thuật phức tạp và thách thức hơn đáng kể. Đối với phân loại ảnh thông thường, mô hình hoạt động trong một tập đóng (closed-set), nơi các nhãn lớp ở giai đoạn kiểm thử hoàn toàn nằm trong tập danh mục đã biết trước khi huấn luyện. Ngược lại, thách thức cốt lõi của Vehicle ReID nằm ở cơ chế truy vấn tập mở (open-set retrieval). Điều này đồng nghĩa với việc định danh (ID) của các phương tiện trong tập kiểm thử hoàn toàn tách biệt và chưa từng xuất hiện trong quá trình huấn luyện.

Do đó, mục tiêu của hệ thống không phải là ghi nhớ hay phân loại các nhãn lớp cố định, mà là học cách ánh xạ hình ảnh phương tiện vào một không gian nhúng (embedding space) có tính tổng quát hóa cao. Trong không gian này, khoảng cách giữa các vector đặc trưng phải phản ánh chính xác mức độ tương đồng về mặt thị giác của phương tiện.

Bên cạnh tính chất open-set, độ phức tạp của Vehicle ReID còn đến từ hai thách thức lớn về phân phối dữ liệu [3]:

- Sự tương đồng giữa các lớp (Inter-class similarity):** Trong môi trường đô thị, các phương tiện được sản xuất hàng loạt theo dây chuyền công nghiệp. Do đó, hai phương tiện hoàn toàn khác nhau về mặt pháp lý (khác chủ sở hữu, khác biển số) nhưng nếu có cùng thương hiệu, mẫu mã, thể hệ sản xuất và màu sắc thì sẽ sở hữu ngoại hình gần như y hệt nhau. Khi quan sát từ khoảng

cách xa, qua các camera có độ phân giải hạn chế hoặc từ các góc chụp chính diện, các đặc trưng toàn cục của chúng trở nên bất biến, khiến mô hình rất dễ bị nhầm lẫn nếu không trích xuất được các chi tiết cục bộ tinh vi như tem xe hoặc các phụ kiện trang trí riêng biệt.

- **Sự khác biệt trong nội bộ lớp (Intra-class variance):** Hình ảnh của cùng một phương tiện có thể biến đổi một cách cực đoan khi được ghi lại bởi các camera khác nhau trong hệ thống. Sự sai khác này bị gây ra bởi ba tác nhân chính:

- *Sự thay đổi góc chụp (Viewpoint variation):* Hình ảnh từ góc nhìn thẳng, nhìn nghiêng 45 độ, hoặc nhìn từ trên cao xuống (từ camera chuyên dụng) mang lại các cấu trúc hình học hoàn toàn khác nhau.
- *Biến đổi điều kiện ánh sáng (Illumination changes):* Sự khác biệt giữa các thời điểm trong ngày (sáng, trưa, tối) hoặc yếu tố thời tiết (nắng, mưa, sương mờ) làm thay đổi sâu sắc phân phối màu sắc hiển thị của phương tiện.
- *Hiện tượng che khuất (Occlusion) và nhiễu nền (Background clutter):* Phương tiện mục tiêu có thể bị che khuất một phần bởi cây cối, biển hiệu hoặc các phương tiện khác xung quanh, khiến mô hình thu nạp phải các thông tin nhiễu không mong muốn.

Chính vì vậy, một mô hình Vehicle ReID thành công đòi hỏi phải trích xuất được các đặc trưng không chỉ mang tính tổng quát mà còn phải có khả năng phân biệt cao, giúp phân biệt được những chi tiết sai khác nhỏ nhất giữa các phương tiện cùng loại.

II. CÁC NGHIÊN CỨU LIÊN QUAN

Trước sự phát triển của học sâu, các thuật toán truyền thống chủ yếu dựa vào các đặc trưng thủ công, với sự tinh chỉnh thông số phụ thuộc vào kinh nghiệm đã được tích lũy trong thời gian dài. Nhìn chung, các đặc trưng thủ công thường phụ thuộc nhiều vào kinh nghiệm thiết kế và khó tổng quát hóa trên các tập dữ liệu phức tạp [2], [3].

Với sự phát triển của các mạng học sâu, các mạng tích chập (CNN) đã trở thành nền tảng để phân loại xe, thay thế cho các phương pháp sử dụng đặc trưng thủ công [2], [3], [5].

A. Các phương pháp học máy truyền thống

Zapletal và Herout [6] đã khai thác biểu đồ phân phối màu sắc (Color Histogram) và biểu đồ hướng gradient (Histogram of Oriented Gradients - HOG). Các đặc trưng này được phân loại thông qua mô hình SVM. Phương pháp này có ưu điểm là chi phí tính toán thấp và dễ triển khai, nhưng khả năng biểu diễn còn hạn chế, đặc biệt trong các trường hợp phương tiện có ngoại hình tương tự nhau hoặc thay đổi mạnh về góc nhìn.

B. Các phương pháp học sâu

Để chuyển tiếp từ phương pháp truyền thống sang học sâu, Liu và cộng sự đã đề xuất khung kiến trúc PROVID [7]. Hệ thống này kết hợp mô hình Bag of Words được xây dựng từ đặc trưng SIFT cùng với các đặc trưng ngữ nghĩa từ mạng CNN để thực hiện quy trình lọc thô (phân loại trên hình dáng) đến

nhận diện tinh (tìm kiếm dựa trên biển số xe). Song song với đó, Zhu và cộng sự giới thiệu mô hình JFSDL dựa trên cấu trúc mạng Siamese, cho phép hệ thống đồng thời tối ưu hóa việc học biểu diễn đặc trưng và học khoảng cách tương đồng (metric learning) giữa các cặp hình ảnh phương tiện [8].

1) *Học đặc trưng toàn cục và cục bộ:* Để giải quyết triệt để hiện tượng tương đồng giữa các lớp, các nghiên cứu hiện đại thường tập trung vào việc trích xuất và kết hợp cả đặc trưng toàn cục lẫn đặc trưng cục bộ. He và cộng sự đã đề xuất phương pháp bảo tồn đặc trưng cục bộ thông qua cơ chế vùng quan tâm (Region of Interest - ROI), giúp mạng nơ-ron tập trung vào các phân vùng ảnh giàu thông tin [9]. Bên cạnh đó, các cơ chế chú ý cũng được sử dụng rộng rãi nhằm tăng cường khả năng chọn lọc đặc trưng. Woo và cộng sự đề xuất mô-đun CBAM, kết hợp chú ý theo kênh và không gian để tinh chỉnh đặc trưng một cách thích ứng [10]. Thay vì chỉ dùng chú ý kênh bằng cách gộp trung bình như các phương pháp trước đó, CBAM tính toán kết hợp cả đặc trưng gộp trung bình và gộp cực đại để nắm bắt thông tin đối tượng chi tiết hơn. Chang và Zhu tiếp tục tích hợp CBAM với học đa tác vụ nhằm cải thiện hiệu quả trích xuất đặc trưng [11]. Mạng MDFE-Net sử dụng cơ chế chú ý phi cục bộ (Non-local Attention - NLA) để thiết lập mối quan hệ phụ thuộc xa giữa các pixel, giúp mô hình bắt được các chi tiết cá nhân hóa nhỏ nhất [12]. Xu và cộng sự đề xuất mạng SSR-Net ứng dụng mạng tích chập đồ thị (Graph Convolutional Network) nhằm mô hình hóa một cách tường minh mối quan hệ cấu trúc không gian phức tạp giữa các đặc trưng cục bộ và toàn cục [13].

2) *Học đặc trưng thuộc tính và góc nhìn:* Một hướng đi phổ biến để khắc phục sự khác biệt nội lớp là nhúng các thông tin thuộc tính phụ trợ vào quá trình huấn luyện. Li và cộng sự xây dựng mạng DF-CVTC để học đặc trưng hình ảnh dưới sự hướng dẫn của các thuộc tính như góc nhìn camera, loại xe và màu sắc [14]. Chu và cộng sự đề xuất VANet, trong đó quá trình so sánh được chia thành hai trường hợp cùng góc nhìn và khác góc nhìn để tối ưu hóa không gian khoảng cách tương ứng [15]. Tương tự, mô hình VOC-ReID của Zhu và cộng sự xem xét bộ ba (Phương tiện - Hướng - Camera), mỗi nhánh trích xuất một ma trận khoảng cách và kết hợp lại để tạo ma trận khoảng cách cuối cùng [5], trong đó sự tương đồng bối cảnh được xử lý cho đặc trưng camera, hình dáng xe được xử lý cho đặc trưng hướng. Nhằm giải quyết hạn chế của việc chỉ truy vấn bằng một hình ảnh duy nhất, Zheng và cộng sự đề xuất mạng VCNet phục vụ cho bài toán nhận diện đa truy vấn, cho phép tổng hợp và bổ sung thông tin từ nhiều góc nhìn khác nhau của cùng một phương tiện để tạo ra một vector định danh toàn diện [16].

3) *Khai thác thông tin Không - Thời gian (Spatio - Temporal Information):* Bên cạnh các đặc trưng thị giác thuần túy, thông tin không - thời gian cung cấp các ràng buộc vật lý để loại bỏ các kết quả sai lệch và không hợp lý. PROVID khai thác vị trí camera và mốc thời gian để thực hiện xếp hạng lại (re-ranking) kết quả truy xuất [7]. Shen và cộng sự mô hình hóa bài toán dựa trên ràng buộc liên camera bằng cách sử dụng Trường ngẫu nhiên Markov chuỗi (Chain Markov Random Field - Chain MRF). Mô hình này đánh giá và đề xuất

các chuỗi quỹ đạo di chuyển hợp lệ của phương tiện, sau đó áp dụng mạng Siamese-CNN kết hợp với Path-LSTM để chấm điểm độ tương đồng động của các quỹ đạo này, mang lại độ chính xác vượt trội trong môi trường thực tế [17], cụ thể một phương tiện phải tồn tại ở thời điểm B nếu phương tiện tại thời điểm C và thời điểm A là cùng phương tiện.

4) *Mạng đối nghịch tạo sinh (GAN)*: Sự thiếu hụt về mặt đa dạng dữ liệu huấn luyện thường dẫn đến hiện tượng quá khớp. Để giải quyết bài toán thiếu hụt này, Lou và cộng sự đã giới thiệu bộ dữ liệu quy mô lớn VERI-Wild, đồng thời đề xuất phương pháp FDA-Net. Phương pháp này ứng dụng mạng đối nghịch tạo sinh để sinh ra các mẫu âm tính khó trực tiếp trong không gian đặc trưng. Các mẫu khó này giúp mô hình học được ranh giới phân biệt tốt hơn giữa các phương tiện có ngoại hình tương tự, từ đó cải thiện khả năng tổng quát hóa [18].

5) *Kiến trúc Transformer*: Trong những năm gần đây, sự dịch chuyển từ kiến trúc CNN sang các mô hình Transformer dựa trên cơ chế tự chú ý (Self attention) đã tạo nên một bước nhảy vọt về mặt hiệu năng. He và cộng sự đã giới thiệu TransReID, một kiến trúc dựa trên Vision Transformer cho bài toán ReID. Bằng cách tích hợp mô-đun phân chia bản vá xáo trộn (Jigsaw Patch Module - JPM) cùng với việc nhúng thông tin bối cảnh (side-information embedding - SIE), TransReID có khả năng thiết lập mối quan hệ ngữ cảnh toàn cục tốt hơn đáng kể so với các cơ chế tích chập cục bộ của CNN [19].

6) *Học không giám sát*: Ngoài các phương pháp có giám sát, học không giám sát và tự giám sát cũng đang trở thành hướng nghiên cứu quan trọng nhằm giảm sự phụ thuộc vào dữ liệu gán nhãn thủ công. Wang và cộng sự đề xuất phương pháp kết hợp Segment Anything Model (SAM) và Masked Autoencoder (MAE), trong đó SAM được sử dụng để tách vùng phương tiện khỏi nền, còn MAE hỗ trợ mô hình tự học biểu diễn định danh từ dữ liệu chưa gán nhãn [2]. Hướng tiếp cận này đặc biệt phù hợp với các hệ thống thực tế, nơi dữ liệu camera rất lớn nhưng việc gán nhãn thủ công tốn nhiều thời gian và chi phí.

7) *Tối ưu hóa huấn luyện*: Song song với việc thiết kế các kiến trúc mạng phức tạp ghép nối nhiều nhánh đặc trưng (multi-branch), một hướng đi quan trọng khác là cải thiện hiệu suất thông qua các thủ thuật huấn luyện mạng. Luo và cộng sự đã chỉ ra rằng, chỉ cần sử dụng duy nhất các đặc trưng toàn cục trên một kiến trúc cơ sở tiêu chuẩn, mô hình tái nhận diện người/phương tiện vẫn có thể đạt được độ chính xác vượt trội nếu được tối ưu hóa đúng cách [20].

III. PHÁT BIỂU BÀI TOÁN

Bài toán Vehicle Re-Identification (Vehicle ReID) là bài toán truy xuất phương tiện, với mục tiêu xác định xem các ảnh chụp từ nhiều camera khác nhau có thuộc cùng một phương tiện hay không.

A. Quy trình hoạt động tổng quát

- 1) Tiếp nhận ảnh phương tiện: Ảnh thu được từ camera được đưa vào hệ thống phát hiện đối tượng để xác định

vị trí phương tiện trong khung hình và cắt vùng ảnh tương ứng.

- 2) Trích xuất đặc trưng: Ảnh phương tiện sau khi được cắt được đưa vào mô hình trích xuất đặc trưng để sinh ra vector đặc trưng. Các vector đặc trưng của cùng một phương tiện được kỳ vọng nằm gần nhau trong không gian đặc trưng, ngược lại, các vector của những phương tiện khác nhau nằm cách xa nhau.
- 3) So sánh đặc trưng: Vector đặc trưng của ảnh truy vấn được so sánh với các vector đặc trưng trong gallery, được tạo ra tương tự ở bước 2.
- 4) Truy vấn và xếp hạng: Dựa trên độ đo tương đồng, hệ thống sắp xếp các ảnh trong gallery và trả về những kết quả có khả năng thuộc cùng phương tiện với ảnh truy vấn.

B. Đầu vào và đầu ra

- **Đầu vào:** Bài toán nhận một ảnh truy vấn I_q chứa phương tiện cần tìm kiếm và một tập ảnh thư viện (gallery) $G = \{I_1, I_2, \dots, I_N\}$ gồm các ảnh phương tiện được thu thập từ nhiều camera khác nhau. Trong giai đoạn huấn luyện, mỗi ảnh I_k được gán nhãn định danh phương tiện L_k .
- **Đầu ra:** Danh sách các ảnh trong gallery được sắp xếp theo mức độ tương đồng với ảnh truy vấn I_q , ưu tiên các kết quả được ghi nhận từ những camera khác. Các ảnh có khả năng thuộc cùng ID với ảnh truy vấn sẽ có độ tương đồng cao hơn và được xếp ở các vị trí đầu trong danh sách Rank- k . Trong quá trình đánh giá, các ảnh có cùng ID phương tiện và cùng ID camera với ảnh truy vấn được loại bỏ vì không phản ánh đúng khả năng truy xuất cross-camera.

Mục tiêu của Vehicle ReID là học một hàm trích xuất đặc trưng $f(\cdot; \theta)$, trong đó θ là tập tham số của mô hình. Với một ảnh đầu vào I , hàm f ánh xạ ảnh này thành vector đặc trưng $E = f(I; \theta)$ trong không gian đặc trưng. Mức độ tương đồng giữa ảnh truy vấn p và ảnh gallery g được xác định dựa trên hai vector đặc trưng tương ứng:

$$\text{Sim}(p, g) = d(f(p, \theta), f(g, \theta)) \quad (1)$$

trong đó $d(\cdot, \cdot)$ là một độ đo tương đồng hoặc khoảng cách trong không gian đặc trưng.

Để học được hàm f , mô hình cần tối ưu tham số θ trên tập dữ liệu huấn luyện sao cho các ảnh cùng ID có biểu diễn gần nhau, trong khi các ảnh khác ID được tách xa nhau. Mục tiêu tối ưu có thể được biểu diễn như sau:

$$\theta^* = \arg \min_{\theta} \sum_{k=1}^N \mathbb{E}(f(I_k; \theta), L_k) \quad (2)$$

trong đó, $\mathbb{E}$ là hàm mất mát tổng quát dùng để huấn luyện mô hình. Hàm mất mát này thường kết hợp giữa thành phần học phân loại và thành phần học khoảng cách:

$$\mathbb{E} = \lambda_1 L_C + \lambda_2 L_M, \quad (3)$$

trong đó L_C là mất mát phân loại (classification loss) dùng để phân loại ID phương tiện; L_M là mất mát độ đo (metric

loss) nhằm tăng khả năng tách biệt giữa các phương tiện trong không gian đặc trưng; λ_1, λ_2 là trọng số đóng góp tương ứng của từng mất mát.

Việc chỉ sử dụng các hàm metric loss, chẳng hạn như Triplet loss truyền thống, thường gặp một số hạn chế như tốc độ hội tụ chậm, nhạy cảm với cách chọn mẫu huấn luyện và có thể bỏ qua một phần thông tin phân loại do chỉ tập trung vào chênh lệch khoảng cách giữa các mẫu [1]. Do đó, việc kết hợp nhiều hàm mất mát có thể giúp các thành phần bổ trợ lẫn nhau, cải thiện hiệu quả tối ưu và tăng năng lực phân biệt của mô hình [11].

Hàm mất mát phân loại, chẳng hạn Cross-Entropy hay ID Loss, hướng mô hình đến việc phân tách rõ ràng các lớp ID thông qua các siêu phẳng trong không gian đặc trưng. Cách tối ưu này đặc biệt phù hợp với các biểu diễn được so sánh bằng khoảng cách góc hoặc độ tương đồng cosine [13], [20]. Trong khi đó, metric loss, chẳng hạn Triplet Loss hoặc Center Loss, tập trung trực tiếp vào cấu trúc hình học của không gian đặc trưng bằng cách kéo gần các mẫu cùng ID và đẩy xa các mẫu khác ID [20]. Sự kết hợp giữa hai nhóm hàm mất mát này giúp mô hình học được các đặc trưng có tính phân biệt cao và ổn định hơn [8], [20].

Các nghiên cứu thực nghiệm cho thấy việc huấn luyện kết hợp nhiều mục tiêu mất mát có thể giúp quá trình tối ưu ổn định hơn và cải thiện tốc độ hội tụ so với việc chỉ sử dụng một hàm mất mát đơn lẻ [11]. Ngoài ra, việc bổ sung Cross-Entropy vào các mô hình học metric thường giúp cải thiện các chỉ số truy xuất quan trọng như mAP và Rank-1 [11], [15].

C. Các giai đoạn xử lý

Quy trình thực hiện bài toán được chia làm hai giai đoạn chính:

Giai đoạn 1: Xây dựng cơ sở dữ liệu đặc trưng

- *Huấn luyện*: Hàm trích xuất đặc trưng $f(\cdot; \theta)$ được huấn luyện trên tập dữ liệu có nhãn nhằm tối ưu hàm mất mát $\mathbb{E}$.
- *Trích xuất đặc trưng gallery*: Sau khi huấn luyện, toàn bộ ảnh trong tập gallery được đưa qua mô hình để trích xuất vector đặc trưng và lưu trữ thành tập $G_E = \{E_1, E_2, \dots, E_N\}$.

Giai đoạn 2: Thực hiện truy xuất

- *Sinh vector truy vấn*: Ảnh truy vấn I_q được đưa qua mô hình để tạo vector đặc trưng $E_q = f(I_q; \theta)$.
- *Tính toán độ tương đồng*: Sử dụng độ đo tương đồng để so sánh E_q với từng vector E_i trong tập gallery.
- *Sắp xếp kết quả*: Hệ thống sắp xếp các ảnh trong gallery theo giá trị $\text{Sim}(E_q, E_i)$ giảm dần và trả về danh sách kết quả Rank- k .

IV. PHƯƠNG PHÁP NGHIÊN CỨU

A. Kiến trúc mạng (Network Architecture)

Kiến trúc mạng được thiết lập dựa trên nguyên lý học đặc trưng sâu phục vụ bài toán truy xuất phương tiện. Thay vì dự đoán nhãn lớp cố định như bài toán phân lớp ảnh thông thường, mục tiêu của mạng là sinh ra một vector đặc trưng có

khả năng biểu diễn ổn định cùng một phương tiện dưới nhiều góc nhìn và điều kiện camera khác nhau.

Mô hình tích hợp mạng backbone mạnh mẽ kết hợp cơ chế chú ý cục bộ của Convolutional Block Attention Module và các kỹ thuật của Bag of Tricks để tối ưu hóa không gian embedding. Dựa vào [12], kiến trúc tổng thể của hệ thống được minh họa trong Hình 1. Các thành phần chính của mô hình như sau:

1) *Backbone ResNet50 và Last Stride Modification*: Mô hình sử dụng ResNet50 được khởi tạo bằng trọng số được tiền huấn luyện trên ImageNetV2 làm thành phần trích xuất đặc trưng chính. Lớp phân loại cuối của mô hình được thay thế để phù hợp với tập dữ liệu huấn luyện. Để phù hợp với bài toán Vehicle ReID đòi hỏi bảo toàn thông tin không gian ở các layer sâu, tham số stride của khối tích chập cuối cùng được điều chỉnh từ 2 xuống 1. Với ảnh đầu vào kích thước 256×256 , điều chỉnh này giúp giữ lại feature map có độ phân giải không gian cao hơn (từ 8×8 tăng lên 16×16) [20], hạn chế sự mất mát các fine-grained đặc trưng cục bộ quan trọng như hình dáng đèn xe, logo, biển số hoặc đường nét thân xe.

2) *Convolutional Block Attention Module (CBAM)*: Để tăng cường khả năng trích xuất các đặc trưng có tính phân biệt cao và giảm thiểu ảnh hưởng của nhiễu môi trường, mô-đun CBAM được tích hợp vào sau các khối tích chập của mạng ResNet50. CBAM thực hiện tính toán tuần tự hai bản đồ chú ý độc lập: Channel Attention và Spatial Attention [10].

Đầu tiên, feature map đầu vào $F \in \mathbb{R}^{C \times H \times W}$ được xử lý qua Channel Attention Module để xác định các đặc trưng kênh quan trọng thông qua việc kết hợp Average Pooling và Max Pooling:

$$M_c(F) = \sigma(\text{MLP}(\text{AvgPool}(F)) + \text{MLP}(\text{MaxPool}(F))) \quad (4)$$

trong đó σ là hàm kích hoạt Sigmoid và MLP là mạng đa tầng chia sẻ trọng số. Feature map trung gian F' được tạo ra bằng phép nhân từng phần tử: $F' = M_c(F) \otimes F$.


Sau đó, bản đồ đặc trưng F' được đưa qua Spatial Attention Module để xác định các vị trí hình học chứa thông tin định danh bằng cách áp dụng tích chập với bộ lọc kích thước 7×7 :

$$M_s(F') = \sigma(f^{7 \times 7}([\text{AvgPool}(F'); \text{MaxPool}(F')])) \quad (5)$$

Feature map đầu ra cuối cùng của khối chú ý được xác định bởi: $F'' = M_s(F') \otimes F'$.

3) *Global Average Pooling và Cấu trúc BNNeck*: Sau khi đi qua module chú ý, feature map F'' được đưa qua lớp Global Average Pooling (GAP) để tổng hợp thông tin không gian thành một vector đặc trưng toàn cục $z = \text{GAP}(F'')$.

Để giải quyết sự xung đột về không gian tối ưu giữa hàm loss phân loại và hàm loss khoảng cách, cấu trúc BNNeck (Batch Normalization Neck) được triển khai ngay sau lớp GAP [20]. Vector đặc trưng thô z được sử dụng trực tiếp để tính toán Triplet Loss nhằm tối ưu hóa khoảng cách Cosine. Đồng thời, z được đưa qua một layer Batch Normalization để tạo ra vector đặc trưng chuẩn hóa z_n . Vector z_n này được kết nối với Classifier Head (lớp Fully Connected) để dự đoán ID phương tiện và tính toán ID Loss trong giai đoạn huấn luyện. Trong giai đoạn inference, Classifier Head bị loại bỏ, và embedding



Hình 1. Kiến trúc tổng thể của hệ thống Vehicle ReID được đề xuất

vector sau chuẩn hóa được sử dụng để so khớp ảnh query và gallery bằng độ đo tương đồng cosine.

B. Hàm mất mát (Loss Functions)

Quá trình huấn luyện sử dụng đa mục tiêu (multi-objective loss) để tối ưu hóa đồng thời khả năng phân loại định danh và khoảng cách trong không gian embedding. Hàm mất mát tổng thể bao gồm hai thành phần chính:

- 1) **ID Loss (Cross-Entropy với Label Smoothing):** Sử dụng để tối ưu khả năng phân loại ID phương tiện dựa trên vector đặc trưng sau chuẩn hóa. Kỹ thuật Label Smoothing [20] với tham số làm mịn $\epsilon = 0.1$ được áp dụng để làm giảm hiện tượng overconfident của mô hình, giúp embedding space có tính tổng quát tốt hơn khi gặp các ID mới ở tập test:

$$L_{CE} = - \sum_{i=1}^C q_i \log(p_i) \quad (6)$$

trong đó p_i là xác suất dự đoán của mô hình, và q_i là nhãn mục tiêu đã được làm mịn.

- 2) **Triplet Loss:** Sử dụng để tối ưu khoảng cách hình học trực tiếp trong embedding space dựa trên vector đặc trưng trước BNNeck. Mỗi bộ ba mẫu gồm ảnh neo (anchor) x_a , ảnh dương (positive) x_p có cùng ID với anchor, và ảnh âm (negative) x_n có ID khác anchor. Hàm này ép khoảng cách giữa anchor và positive nhỏ hơn khoảng cách giữa anchor và negative tối thiểu một giá trị biên $m = 0.3$ [3]:

$$L_{triplet} = [d(f(x_a), f(x_p)) - d(f(x_a), f(x_n)) + m]_+ \quad (7)$$

trong đó $f(\cdot)$ là hàm trích xuất embedding, $d(\cdot, \cdot)$ là khoảng cách Euclid, $d(f(x_a), f(x_p))$ là khoảng cách anchor-positive, $d(f(x_a), f(x_n))$ là khoảng cách anchor-negative, và $[\cdot]_+$ biểu diễn phép toán $\max(\cdot, 0)$.

V. THỰC NGHIỆM

A. Tập dữ liệu và độ đo đánh giá

Nhóm thực hiện đánh giá mô hình đề xuất bằng hai tập dữ liệu Vehicle ReID phổ biến là VeRi776 [7] và VRIC [21],

[22]. VeRi776 là tập hợp 776 xe được thu thập từ 20 camera an ninh trong phạm vi 1 km^2 , bao gồm 51035 ảnh với các thông tin như màu sắc, phân loại, camera ghi nhận. Ngoài ra, tập dữ liệu còn có thông tin về khoảng cách và vị trí của camera. VRIC là tập hợp 5622 xe được thu thập 24 khu vực, bao gồm 60430 ảnh có điều kiện môi trường đa dạng. Chi tiết phân phối dữ liệu ở Bảng I.

Nhóm sử dụng hai độ đo mAP (mean Average Precision) và CMC@k (Cumulative Matching Characteristic at rank k) để đánh giá hiệu suất truy xuất của mô hình. Trong quá trình đánh giá, các ảnh trong gallery có đồng thời ID phương tiện và ID camera trùng với ảnh truy vấn được xem là ảnh rác (junk images) và bị loại khỏi danh sách xếp hạng, vì chúng không phản ánh đúng khả năng truy xuất cross-camera của mô hình.

mAP đánh giá chất lượng tổng thể của toàn bộ truy vấn, được xác định bởi công thức

$$mAP = \frac{\sum_{q=1}^Q AP(q)}{Q} \quad (8)$$

trong đó Q là tổng số ảnh truy vấn, $AP(q)$ là độ chính xác trung bình khi truy vấn ảnh q , $AP(q)$ của một ảnh được xác định bởi

$$AP(q) = \frac{1}{N_g} \sum_{k=1}^N P(k) rel(k) \quad (9)$$

trong đó $P(k)$ là độ chính xác của truy vấn tới hạng k , $rel(k)$ bằng 1 khi kết quả truy vấn tại hạng k có cùng ID với ảnh truy vấn q , N_g là tổng số ảnh có cùng ID với ảnh truy vấn q . $P(k)$ của một ảnh được xác định bởi

$$P(k) = \frac{\sum_{i=1}^k rel(i)}{k} \quad (10)$$

CMC đánh giá xác suất xuất hiện ít nhất một ảnh có cùng ID với ảnh truy vấn trong k kết quả đầu tiên. CMC tại hạng k được xác định bởi

$$CMC@k = \frac{\sum_{i=1}^Q m(q_i, k)}{Q} \quad (11)$$

Bảng I
CHI TIẾT PHÂN PHỐI TẬP DỮ LIỆU

Tập dữ liệu	Tổng ảnh	Tập huấn luyện		Tập kiểm thử		
		Ảnh	ID phương tiện	Ảnh gallery	Ảnh truy vấn	ID phương tiện
VeRi776	51035	37778	500	11579	1678	276
VRIC	60430	54808	2811	2811	2811	2811

trong đó $m(q_i, k)$ bằng 1 nếu tồn tại ít nhất một ảnh trong top- k kết quả của truy vấn q_i có cùng ID với q_i , ngược lại bằng 0.

B. Chi tiết cài đặt

Thực nghiệm được thực hiện trên nền tảng Kaggle với GPU T4 x2. Mô hình được cài đặt bằng Python 3.12 và PyTorch 2.10. Tương tự các thiết lập phổ biến trong Vehicle ReID, nhóm sử dụng ResNet50 [12], [16] được tiền huấn luyện trên ImageNetV2 làm backbone để trích xuất đặc trưng. Các mô hình được huấn luyện trên tập VeRi776 và đánh giá trên VeRi776 và VRIC nhằm kiểm tra khả năng truy xuất trong cùng miền dữ liệu và khác miền dữ liệu.

Tất cả ảnh đầu vào được thay đổi kích thước về 256×256 và chuẩn hóa theo phân phối của ImageNetV2. Trong quá trình huấn luyện, nhóm áp dụng các kỹ thuật tăng cường dữ liệu gồm lật ngang ngẫu nhiên nhằm mô phỏng sự thay đổi hướng di chuyển của phương tiện, điều chỉnh độ sáng để tăng khả năng thích nghi với các điều kiện chiếu sáng khác nhau như ngày, đêm hoặc bóng râm và biến đổi affine để giảm sự phụ thuộc của mô hình vào vị trí chính xác của phương tiện trong khung hình. Đối với các cấu hình sử dụng Bag of Tricks (BOT), kỹ thuật xóa vùng ngẫu nhiên (random erasing) được bổ sung nhằm ép mô hình học các đặc trưng cục bộ bền vững khi phương tiện bị vật cản hoặc phương tiện khác che khuất một phần.

Cấu hình hyperparameter chung được thiết lập như sau:

- **Optimizer:** AdamW với weight decay bằng 5×10^{-4} .
- **Batch size:** 32 ảnh. Mỗi batch được lấy mẫu theo ID, trong đó mỗi ID có 8 ảnh để hỗ trợ việc tính toán metric loss.
- **Learning rate:** Learning rate của các lớp mới là 3×10^{-4} , trong khi learning rate của backbone được đặt ở 3×10^{-5} .
- **Scheduler:** Cosine Annealing được sử dụng để giảm learning rate trong quá trình huấn luyện; với các cấu hình BOT, nhóm bổ sung Linear Warmup Scheduler trong 10 epoch đầu, với learning rate nhỏ nhất là 1×10^{-5} .
- **Số epoch:** Mỗi mô hình được huấn luyện trong 60 epoch.
- **Embedding dimension:** Vector đặc trưng đầu ra có số chiều là 2048.
- **Loss function:** Hàm mất mát gồm thành phần phân loại và độ đo; metric loss sử dụng biên bằng 0.3. Trọng số đóng góp của mỗi mất mát là như nhau $\lambda_1 = \lambda_2 = 1$.

Nhóm xây dựng và so sánh bốn cấu hình mô hình. Cấu hình Baseline gồm backbone ResNet50, lớp Global Average Pooling (GAP), embedding layer và classifier head. Với cấu hình CBAM, mô-đun CBAM được đặt ở cuối các major

block của ResNet50. Với cấu hình BOT, nhóm bổ sung Batch Normalization sau lớp GAP, thay đổi stride ở major block cuối của ResNet50, label smoothing, random erasing và warmup learning rate.

Các thông số riêng của từng cấu hình được trình bày trong Bảng II.

C. Kết quả định lượng

Để đánh giá hiệu quả triển khai, nhóm so sánh các mô hình tự xây dựng với ReID Strong Baseline (ReIDSB) [20] được huấn luyện trên VeRi776. Kết quả được tổng hợp trong Bảng III.

Trên dữ liệu VeRi776, các cải tiến kỹ thuật đóng góp không đáng kể vào kết quả kiểm thử. Mô-đun CBAM làm giảm kết quả dự đoán tổng thể, ngược lại BOT giúp tăng hiệu quả truy vấn dù không có thay đổi đáng kể về cấu trúc mô hình. Với ReIDSB, các tiêu chí đều cao hơn với mAP cao hơn từ 5-10%, cho thấy mô hình có hiệu quả tìm kiếm tổng quát khá tốt và có khả năng đưa ít nhất một ảnh đúng của cùng phương tiện lên vị trí đầu tiên trong danh sách truy xuất. Nói cách khác, ReIDSB này rất mạnh trong việc tìm kiếm các mẫu “easy positive”, tức là những ảnh cùng ID có góc nhìn, điều kiện ánh sáng hoặc đặc điểm trực quan tương đối gần với ảnh truy vấn.

Tuy nhiên, mAP của các mô hình đều thấp hơn đáng kể so với Rank-1. Khoảng cách này cho thấy mặc dù mô hình thường tìm được một kết quả đúng ở vị trí đầu, nhưng chưa tối ưu trong việc đưa toàn bộ các ảnh đúng của cùng một phương tiện lên các thứ hạng cao. Đây là hạn chế quan trọng trong bài toán Vehicle ReID, vì một phương tiện có thể xuất hiện ở nhiều camera với góc nhìn, độ phân giải, ánh sáng và mức độ che khuất khác nhau. Do đó, mAP phản ánh rõ hơn khả năng truy xuất toàn diện trong điều kiện cross-camera matching.

Khi thực hiện thử nghiệm thực tế trên tập dữ liệu VRIC, hiệu năng của tất cả các biến thể kiến trúc đều ghi nhận mức sụt giảm sâu sắc so với trên tập VeRi776, biểu thị khoảng cách miền dữ liệu (Domain Gap) vô cùng lớn. Tuy nhiên, các kỹ thuật cải tiến thành phần vẫn chứng minh được vai trò và giá trị thực tiễn rõ rệt đối với không gian nhúng cơ sở.

Cụ thể, cấu hình tích hợp các thủ thuật huấn luyện mạng (+ BOT) giúp chỉ số mAP tăng từ 17.90% lên 23.20%, đồng thời kéo chỉ số Rank-1 từ 11.38% lên 16.61%. Sự gia tăng này chứng minh rằng các cơ chế điều hòa dữ liệu nặng như xóa vùng ngẫu nhiên (random erasing) và làm mịn nhãn (label smoothing) đã giúp vector đặc trưng giảm bớt sự nhạy cảm đối với các phân phối nền hoặc vật cản nhiễu. Cấu hình tích hợp mô-đun chú ý khi đứng độc lập (+ CBAM) mang lại mức cải thiện khiêm tốn với mAP đạt 18.45% và Rank-1 đạt 12.20%.

Bảng II
THÔNG SỐ CÀI ĐẶT RIÊNG CỦA TỪNG MÔ HÌNH

Mô hình	Warmup	Warmup LR	Random erase	Label smoothing	Last stride
Baseline	0	-	Không	Không	2
+ BOT	10	1×10^{-5}	Có	Có	1
+ CBAM	0	-	Không	Không	2
+ BOT + CBAM	10	1×10^{-5}	Có	Có	1

Bảng III
SO SÁNH KẾT QUẢ ĐỊNH LƯỢNG TRÊN HAI TẬP DỮ LIỆU VeRi776 VÀ VRIC

Mô hình	VeRi776				VRIC			
	mAP	Rank-1	Rank-5	Rank-10	mAP	Rank-1	Rank-5	Rank-10
Baseline	64.34%	89.87%	95.35%	97.08%	17.90%	11.38%	23.66%	30.31%
+ BOT	66.10%	91.90%	96.72%	98.09%	23.20%	16.61%	29.14%	35.72%
+ CBAM	61.58%	88.80%	94.34%	96.66%	18.45%	12.20%	23.44%	30.27%
+ BOT + CBAM	66.00%	91.48%	96.54%	98.21%	26.71%	18.85%	34.29%	41.62%
ReIDSB	74.40%	93.30%	97.40%	98.50%	23.46%	16.47%	29.74%	37.03%

Đáng chú ý, cấu hình kết hợp đồng thời cả hai giải pháp nâng cao (+ BOT + CBAM) mang lại kết quả thực nghiệm tối ưu nhất trên miền ngoại lai VRIC, đạt mức mAP 26.71%, Rank-1 đạt 18.85%, Rank-5 đạt 34.29% và Rank-10 đạt 41.62%. Đồ thị chỉ số này thậm chí vượt trội hơn hẳn so với mô hình Strong Baseline tham chiếu tiêu chuẩn (chỉ đạt mAP 23.46% và Rank-1 16.47%). Kết quả này khẳng định cơ chế lọc kênh và tái định vị không gian thích ứng của mô-đun chú ý CBAM khi được vận hành dựa trên cấu trúc hình học chuẩn hóa Batch Normalization của BOT sẽ củng cố mạnh mẽ tính tổng quát hóa sâu, cho phép hệ thống chống chịu tốt hơn trước các rào cản nhiễu ảnh thực tế.

VI. PHÂN TÍCH VÀ ĐÁNH GIÁ

Bên cạnh các chỉ số định lượng, việc phân tích các trường hợp xếp hạng sai (false match) cung cấp cơ sở kỹ thuật để đánh giá giới hạn của kiến trúc mô hình hiện tại.

A. Hiện tượng suy giảm đặc trưng không gian

Quan sát các kết quả truy xuất ở những thứ hạng cao (Hình 2) cho thấy mô hình vẫn xuất hiện các trường hợp nhận diện sai khi ảnh truy vấn và ảnh dương tính giả có độ tương đồng lớn về màu sắc tổng thể và góc nhìn, mặc dù giữa chúng vẫn tồn tại các chi tiết nhận dạng khác biệt.

Nguyên nhân kỹ thuật chính đến từ lớp GAP. Lớp GAP nén bản đồ đặc trưng không gian 2D thành một vector đặc trưng 1D, làm suy giảm thông tin về cấu trúc không gian của đối tượng. Do đó, các đặc trưng fine-grained chiếm diện tích nhỏ trong ảnh, chẳng hạn biển số, hình dạng đèn pha, kính xe hoặc các chi tiết trang trí cục bộ, có thể bị lấn át bởi các đặc trưng macro như màu sơn và kiểu dáng tổng thể. Sự áp đảo của các đặc trưng macro khiến các vector đặc trưng của hai phương tiện khác ID trở nên tương đồng trong không gian đặc trưng.

B. Hiện tượng trùng mẫu xe

Ngoài lỗi do suy giảm đặc trưng không gian, một số false positive xuất hiện khi các phương tiện khác ID có hình dáng,

màu sắc và ngoại quan rất giống nhau. Trong các trường hợp này, những chi tiết có tính phân biệt cao như biển số, logo hoặc dấu hiệu riêng trên thân xe không được thể hiện đủ rõ, khiến mô hình có thể nhận diện đúng nhóm đặc điểm của xe nhưng không phân biệt chính xác ID phương tiện. Hiện tượng này thường gặp ở các phương tiện được thiết kế hoặc trang trí đồng nhất, chẳng hạn xe taxi, xe buýt hoặc xe thuộc cùng một đội vận hành (Hình 3). Với các mẫu có mức độ tương đồng ngoại quan quá cao, lỗi truy xuất khó tránh khỏi, hiện tượng mô hình dự đoán sai là chấp nhận được vì ngay cả quan sát của con người cũng có thể không đủ cơ sở để xác định chắc chắn hai ảnh có thuộc cùng một phương tiện hay không.

C. Mật độ phân phối độ tương đồng

Dựa trên phân bố mật độ của độ tương đồng cosine trong Hình 4 và Hình 5, có thể thấy mô hình đã học được khả năng phân tách cơ bản giữa các cặp ảnh cùng ID và khác ID.

So sánh giữa Baseline và cấu hình CBAM cho thấy hình dạng tổng thể của hai phân phối không thay đổi quá lớn, nghĩa là cấu trúc của không gian đặc trưng vẫn được duy trì. Tuy nhiên, phân phối liên lớp trong cấu hình CBAM có xu hướng hẹp hơn và đạt đỉnh cao hơn một chút so với Baseline. Điều này cho thấy cơ chế chú ý của CBAM có thể giúp mô hình tập trung tốt hơn vào các vùng đặc trưng của phương tiện và làm cho các mẫu khác ID ít phân tán hơn.

Khi bổ sung BOT, phân phối liên lớp bị kéo về vùng độ tương đồng rất thấp, cho thấy mô hình phân tách các phương tiện khác ID hiệu quả hơn. Tuy nhiên, phân phối nội lớp cũng bị kéo về phía giá trị thấp hơn. Hiện tượng này có thể đến từ các thành phần như label smoothing và random erasing: label smoothing làm giảm xu hướng mô hình quá tự tin vào nhãn phân loại, trong khi random erasing tạo ra các biến thể bị che khuất nhân tạo, khiến các ảnh cùng ID trở nên khác biệt hơn ở đầu vào. Do đó, độ tương đồng tuyệt đối giữa các ảnh cùng ID có thể giảm, mặc dù thứ tự xếp hạng tương đối vẫn được cải thiện nếu các mẫu khác ID bị đẩy xuống vùng tương đồng thấp hơn.

Ở cấu hình kết hợp BOT + CBAM, hình dạng phân phối chịu ảnh hưởng mạnh từ BOT, trong khi tác động tinh chỉnh cục bộ của CBAM không thể hiện rõ như khi xét riêng cấu hình CBAM. Điều này cho thấy trong thiết lập hiện tại, các kỹ thuật tăng cường dữ liệu của BOT đóng vai trò chi phối hơn đối với cấu trúc phân phối đặc trưng.

Nhìn chung, các biểu đồ KDE cho thấy mục tiêu của các cải tiến không nhất thiết là đẩy độ tương đồng cosine của mọi cặp ảnh cùng ID lên gần 1.0. Trong bài toán Vehicle ReID, yếu tố quan trọng hơn là thứ tự xếp hạng tương đối: ảnh đúng ID cần có độ tương đồng cao hơn ảnh khác ID. Vì vậy, ngay cả khi độ tương đồng nội lớp giảm, mô hình vẫn có thể truy xuất hiệu quả nếu độ tương đồng liên lớp giảm mạnh hơn.

Ngoài ra, việc đánh giá vùng giao thoa (overlap region) giữa phân phối nội lớp và phân phối liên lớp là một cách quan trọng để phân tích chất lượng không gian đặc trưng. Vùng giao thoa là khu vực mà hai loại mẫu có độ tương đồng gần nhau: mẫu dương tính khó là các ảnh cùng ID nhưng có độ tương đồng thấp, mẫu âm tính khó là các ảnh khác ID nhưng có độ tương đồng cao. Đây chính là vùng nhầm lẫn của mô hình, hệ thống dễ xếp hạng sai bằng cách đưa ảnh khác ID lên trước ảnh cùng ID.

Diện tích vùng giao thoa phản ánh mức độ chồng lấn xác suất giữa mẫu dương và mẫu âm. Nếu diện tích vùng giao thoa lớn, xác suất một mẫu rơi vào vùng nhầm lẫn sẽ cao hơn, kéo theo nhiều lỗi dương sai và âm sai hơn. Ngược lại, nếu vùng giao thoa có độ rộng tương đối lớn nhưng mật độ tại vùng thấp, nghĩa là các mẫu khó bị phân tán trên một khoảng độ tương đồng lớn. Điều này phản ánh sự thiếu ổn định của không gian nhúng: một số mẫu dương khó bị đẩy quá xa khỏi cụm cùng ID, trong khi các mẫu âm khó bị kéo quá gần về phía ảnh truy vấn.

Trong cấu hình Baseline và CBAM, khoảng cách giữa hai đỉnh phân phối cho thấy mô hình đã học được khả năng phân tách cơ bản. Tuy nhiên, phần đuôi của hai phân phối vẫn giao nhau đáng kể. Phân phối liên lớp có đuôi kéo dài sang vùng độ tương đồng cao, tương ứng với các phương tiện khác ID nhưng có ngoại hình rất giống nhau. Ngược lại, phân phối nội lớp có đuôi kéo về vùng độ tương đồng thấp, tương ứng với các ảnh cùng phương tiện nhưng thay đổi mạnh về góc nhìn, ánh sáng hoặc mức độ che khuất. Chính sự giao nhau của hai phần đuôi này tạo ra vùng giao thoa và làm tăng khả năng xếp hạng sai.

Với các cấu hình có BOT, nếu chỉ nhìn riêng độ tương đồng, có thể đánh giá mô hình dường như kém hơn vì một số ảnh cùng ID không còn đạt độ tương đồng cosine cao như Baseline. Tuy nhiên, trong bài toán Vehicle ReID, yếu tố quyết định là biên phân tách tương đối: ảnh cùng ID chỉ cần có độ tương đồng cao hơn ảnh khác ID để được xếp trước trong danh sách truy xuất. Vì vậy khi BOT làm giảm độ tương đồng liên lớp mạnh hơn mức giảm của độ tương đồng nội lớp, mô hình vẫn có thể cải thiện hiệu năng xếp hạng.

D. Cross-Dataset Domain Shift Analysis

Để khảo sát năng lực tổng quát hóa của hệ thống, nhóm thực hiện đánh giá chéo tập dữ liệu trên miền đích VRIC nhằm xác

định mức độ ảnh hưởng của khoảng hở phân phối (Domain Gap).

1) *Bảng đối chiếu sai lệch hiệu năng*: Kết quả thực nghiệm cho thấy các chỉ số hiệu suất đều suy giảm đáng kể khi mô hình được huấn luyện trên miền nguồn VeRi-776 và đánh giá trên miền đích VRIC. Mức độ sụt giảm của từng cấu hình được thống kê chi tiết trong Bảng IV.

Bảng IV
MỨC ĐỘ SỤT GIẢM HIỆU SUẤT GIỮA MIỀN NGUỒN VeRi-776 VÀ MIỀN ĐÍCH VRIC CỦA ReIDSB VÀ BOT + CBAM

Cấu hình	Chỉ số	VeRi-776	VRIC	Sụt giảm
ReIDSB	mAP	74.40%	23.46%	-50.94%
ReIDSB	Rank-1	93.30%	16.47%	-76.83%
ReIDSB	Rank-5	97.40%	29.74%	-67.66%
ReIDSB	Rank-10	98.50%	37.03%	-61.47%
BOT + CBAM	mAP	66.00%	26.71%	-39.29%
BOT + CBAM	Rank-1	91.48%	18.85%	-72.63%
BOT + CBAM	Rank-5	96.54%	34.29%	-62.25%
BOT + CBAM	Rank-10	98.21%	41.62%	-56.59%

2) *Phân tích nguyên nhân*: Sự suy giảm chỉ số hiệu năng định lượng xuất phát từ ba nguyên nhân cốt lõi sau:

- 1) **Lệch phân phối miền dữ liệu (Severe Domain Shift)**: Hình ảnh ở miền nguồn (VeRi-776) có độ phân giải thông tin cao, góc quay camera ngang tầm mắt ổn định và điều kiện ánh sáng ban ngày đồng đều, dẫn đến việc mạng tích chập bị quá khớp (overfitting) vào các đặc trưng bối cảnh này. Khi đánh giá trên miền đích (VRIC) - vốn được thu thập từ camera giám sát giao thông thực tế góc cao (Top-down view), độ phân giải thấp do thuật toán nén dữ liệu và chứa nhiều khung hình ban đêm hoặc ngược sáng - mô hình gặp khó khăn trong việc trích xuất các biểu diễn đặc trưng ổn định.
- 2) **Ảnh hưởng của các mẫu ngoại lớp tương đồng (Inter-class Hard Negatives)**: Do độ tương đồng giữa các lớp cao, hệ thống thường xếp hạng sai các mẫu khác ID nhưng có cùng màu sắc và kiểu dáng phổ thông (như Sedan trắng hoặc SUV tối màu) lên các thứ hạng đầu với giá trị tương đồng Cosine lớn. Vì hàm mất mát Triplet tối ưu khoảng cách tương đối dựa trên một biên cố định, mạng có xu hướng phụ thuộc vào các đặc trưng toàn cục vĩ mô (màu sắc, hình dáng tổng thể) và hạn chế khả năng phân biệt các đặc trưng cục bộ vi mô (chi tiết lưới tản nhiệt, logo), dẫn đến hiện tượng dương tính giả.
- 3) **Sai lệch về tỷ lệ hình học (Aspect Ratio Mismatch)**: Quy trình tiền xử lý ảnh thay đổi kích thước tất cả các ảnh thô về kích thước cố định 256×256 . Do đặc thù góc chụp từ trên xuống của tập VRIC, các hộp bao (bounding-box) của phương tiện thường có cấu trúc vuông hoặc bè ngang. Việc thay đổi tỷ lệ khung hình phi tuyến tính này làm biến dạng các cấu trúc không gian cục bộ (lưới tản nhiệt, mâm xe), tạo ra các thành phần nhiễu trong không gian nhúng.

E. Minh họa kết quả truy xuất

Bên cạnh các chỉ số định lượng, nhóm minh họa kết quả truy xuất của bốn cấu hình mô hình trên VeRi776 và VRIC. Trong mỗi nhóm, thứ tự từ trên xuống lần lượt là Baseline, CBAM, BOT và BOT + CBAM.

Các kết quả minh họa cho thấy các cấu hình có BOT thường có xu hướng đưa nhiều ảnh đúng ID hơn vào nhóm kết quả đầu, phù hợp với mức cải thiện Rank- k và mAP trong Bảng III.

VII. KẾT LUẬN VÀ ĐỊNH HƯỚNG PHÁT TRIỂN

A. Kết luận

Báo cáo đã xây dựng và thực nghiệm hệ thống Tái nhận diện Phương tiện (Vehicle ReID) dựa trên kiến trúc backbone ResNet50, kết hợp các thành phần tối ưu bao gồm cấu trúc BNNeck, hàm mất mát đa mục tiêu (ID Loss và Triplet Loss), mô-đun chú ý CBAM và bộ thủ thuật huấn luyện BOT. Hệ thống được đánh giá thực nghiệm nghiêm ngặt trên hai tập dữ liệu VeRi776 và VRIC nhằm khảo sát hiệu quả trích xuất đặc trưng nội miền cũng như năng lực tổng quát hóa chéo miền dữ liệu.

Trên tập dữ liệu VeRi776, các cấu hình tích hợp BOT cho hiệu quả truy xuất cải thiện so với cấu hình Baseline, đạt chỉ số mAP 66.1% và Rank-1 đạt 91.9%. Kết quả này minh chứng cho vai trò của các kỹ thuật điều hòa dữ liệu trong việc tối ưu hóa không gian biểu diễn. Đặc biệt, cấu hình kết hợp BOT + CBAM đạt kết quả tốt nhất trên miền đích VRIC với mAP 26.71%, cải thiện hiệu năng so với mô hình Strong Baseline (ReIDSB) tham chiếu.


Tuy nhiên, kết quả thực nghiệm cũng chỉ ra khoảng cách lớn giữa hai chỉ số mAP và Rank-1 trong toàn bộ các cấu hình. Hiện tượng này phản ánh hạn chế của mô hình trong việc truy xuất đầy đủ các ảnh cùng định danh (ID) dưới sự thay đổi phức tạp của điều kiện camera chéo (cross-camera matching). Khi đánh giá trên tập dữ liệu ngoại lai VRIC, hiệu năng của hệ thống suy giảm mạnh do ảnh hưởng của hiện tượng lệch miền dữ liệu và các mẫu âm tính khó. Qua phân tích định tính các trường hợp false match, các nguyên nhân gây lỗi xếp hạng sai được xác định bao gồm hiện tượng suy giảm chi tiết không gian do hệ quả của lớp GAP và độ tương đồng ngoại quan cao giữa các phương tiện khác nhãn lớp. Do đó, hệ thống cần được cải tiến sâu hơn ở tầng kiến trúc để tăng cường khả năng thích ứng trong các môi trường giao thông thực tế.

B. Định hướng phát triển

Dựa trên các kết quả thực nghiệm và những giới hạn kỹ thuật còn tồn tại, báo cáo đề xuất một số hướng nghiên cứu nhằm cải thiện hiệu năng của hệ thống Vehicle ReID trong tương lai:

- **Cải tiến hàm mất mát (Metric Learning nâng cao):** Thay thế hàm Triplet Loss bằng kiến trúc Circle Loss nhằm tối ưu hóa độc lập tỷ lệ tương đồng nội lớp và ngoại lớp. Giải pháp này giúp thu hẹp khoảng cách hình học giữa các mẫu cùng ID trên mặt cầu không gian Cosine, tăng cường năng lực phân tách các mẫu âm tính khó có ngoại hình tương tự.


- **Xử lý rào cản lệch miền dữ liệu (Unsupervised Domain Adaptation - UDA):** Tích hợp các phương pháp thích nghi miền không giám sát như Mutual Mean-Teacher (MMT) hoặc các mô hình mạng tạo sinh đối nghịch (GAN). Hướng tiếp cận này nhằm giảm thiểu sự sụt giảm hiệu năng khi mô hình hoạt động trong các điều kiện môi trường hoặc điều kiện chiếu sáng thay đổi (như ban đêm hoặc ngược sáng).
- **Tích hợp cơ chế xếp hạng lại (Re-ranking):** Áp dụng thuật toán xếp hạng lại (như k-reciprocal encoding) để tinh chỉnh danh sách kết quả truy xuất sau giai đoạn inference. Phương pháp này hỗ trợ tối ưu hóa thứ tự phân cấp của các mẫu chính xác trong tập gallery, từ đó cải thiện đồng thời hai chỉ số mAP và Rank- k .
- **Khai thác thông tin Không - Thời gian (Spatio-Temporal Metadata):** Kết hợp các siêu dữ liệu phụ trợ bao gồm camera ID, vị trí địa lý và mốc thời gian ghi nhận vào quá trình tính toán ma trận khoảng cách. Việc ràng buộc các đặc trưng thị giác với thông tin không - thời gian giúp loại bỏ các trường hợp dương tính giả khi khoảng thời gian xuất hiện của phương tiện giữa hai vị trí camera vượt quá giới hạn vận tốc thực tế.
- **Tăng cường trích xuất đặc trưng cục bộ (Local Features):** Giảm bớt sự phụ thuộc vào các đặc trưng toàn cục của lớp GAP bằng cách khai thác các đặc trưng hình học mịn (fine-grained). Các hướng cải tiến bao gồm triển khai cơ chế chú ý không gian phân mảnh (Part-based attention), tích hợp kỹ thuật nhận diện ký tự quang học (OCR) đối với biển số, hoặc ứng dụng cơ chế self-attention của kiến trúc Vision Transformer (ViT) để nắm bắt các chi tiết nhận dạng cục bộ.




Hình 2. Các trường hợp false match (viền đỏ) do mất mát chi tiết không gian



Hình 3. Các trường hợp false match (viền đỏ) do cấu trúc xe đồng nhất



Hình 4. Biểu đồ phân bố mật độ (KDE) của độ đo tương đồng cosine trên VeRi776




Hình 5. Biểu đồ phân bố mật độ (KDE) của độ đo tương đồng cosine trên VRIC



Hình 6. Minh họa kết quả truy xuất trên ảnh truy vấn thứ nhất của VeRi776




Hình 7. Minh họa kết quả truy xuất trên ảnh truy vấn thứ hai của VeRi776



Hình 8. Minh họa kết quả truy xuất trên ảnh truy vấn thứ ba của VeRi776



Hình 9. Minh họa kết quả truy xuất trên ảnh truy vấn thứ nhất của VRIC



Hình 10. Minh họa kết quả truy xuất trên ảnh truy vấn thứ hai của VRIC

- [1] A. Amiri, A. Kaya, and A. S. Keceli, “A comprehensive survey on deep-learning-based vehicle re-identification: Models, data sets and challenges,” 2024. DOI: 10.48550/ARXIV.2401.10643 address: <https://arxiv.org/abs/2401.10643>
- [2] Z. Wang, L. Wang, Z. Shi, M. Zhang, Q. Geng, and N. Jiang, “A survey on person and vehicle re-identification,” en, *IET Computer Vision*, vol. 18, no. 8, pp. 1235–1268, Dec. 2024, ISSN: 1751-9632, 1751-9640. DOI: 10.1049/cvi2.12316
- [3] H. Wang, J. Hou, and N. Chen, “A survey of vehicle re-identification based on deep learning,” en,
- [4] Zakria et al., “Trends in vehicle re-identification past, present, and future: A comprehensive review,” 2021. DOI: 10.48550/ARXIV.2102.09744 address: <https://arxiv.org/abs/2102.09744>
- [5] X. Zhu, Z. Luo, P. Fu, and X. Ji, “Voc-reid: Vehicle re-identification based on vehicle-orientation-camera,” en,
- [6] D. Zapletal and A. Herout, “Vehicle re-identification for automatic video traffic surveillance,” en,
- [7] X. Liu, W. Liu, T. Mei, and H. Ma, “Provid: Progressive and multimodal vehicle reidentification for large-scale urban surveillance,” *IEEE Transactions on Multimedia*, vol. 20, no. 3, pp. 645–658, Mar. 2018, ISSN: 1520-9210, 1941-0077. DOI: 10.1109/TMM.2017.2751966
- [8] J. Zhu, H. Zeng, Y. Du, Z. Lei, L. Zheng, and C. Cai, “Joint feature and similarity deep learning for vehicle re-identification,” *IEEE Access*, vol. 6, pp. 43 724–43 731, 2018, ISSN: 2169-3536. DOI: 10.1109/ACCESS.2018.2862382
- [9] B. He, J. Li, Y. Zhao, and Y. Tian, “Part-regularized near-duplicate vehicle re-identification,” in *2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, Long Beach, CA, USA: IEEE, June 2019, pp. 3992–4000, ISBN: 978-1-7281-3293-8. DOI: 10.1109/CVPR.2019.00412 address: <https://ieeexplore.ieee.org/document/8953360/>
- [10] S. Woo, J. Park, J.-Y. Lee, and I. S. Kweon, “Cbam: Convolutional block attention module,” 2018. DOI: 10.48550/ARXIV.1807.06521 address: <https://arxiv.org/abs/1807.06521>
- [11] Y. Chang and Q. Zhu, “A deep learning-based vehicle re-identification algorithm with attention and joint learning,” en, in *Proceedings of the 7th International Conference on Information Technologies and Electrical Engineering*, Guangzhou China: ACM, Nov. 2024, pp. 125–130, ISBN: 979-8-4007-0708-7. DOI: 10.1145/3717934.3717953 address: <https://dl.acm.org/doi/10.1145/3717934.3717953>
- [12] L. Bai and L. Rong, “Vehicle re-identification with multiple discriminative features based on non-local-attention block,” en,
- [13] Z. Xu et al., “Ssr-net: A spatial structural relation network for vehicle re-identification,” en, *ACM Transactions on Multimedia Computing, Communications, and Applications*, vol. 19, no. 6, pp. 1–22, Nov. 2023, ISSN: 1551-6857, 1551-6865. DOI: 10.1145/3578578
- [14] H. Li et al., “Attributes guided feature learning for vehicle re-identification,” 2019. DOI: 10.48550/ARXIV.1905.08997 address: <https://arxiv.org/abs/1905.08997>
- [15] R. Chu, Y. Sun, Y. Li, Z. Liu, C. Zhang, and Y. Wei, “Vehicle re-identification with viewpoint-aware metric learning,” 2019. DOI: 10.48550/ARXIV.1910.04104 address: <https://arxiv.org/abs/1910.04104>
- [16] A. Zheng et al., “Multi-query vehicle re-identification: Viewpoint-conditioned network, unified dataset and new metric,” en, no. arXiv:2305.15764, May 2023, arXiv:2305.15764 [cs.CV]. DOI: 10.48550/arXiv.2305.15764 address: <http://arxiv.org/abs/2305.15764>
- [17] Y. Shen, T. Xiao, H. Li, S. Yi, and X. Wang, “Learning deep neural networks for vehicle re-id with visual-spatio-temporal path proposals,” en,
- [18] Y. Lou, Y. Bai, J. Liu, S. Wang, and L. Duan, “Veri-wild: A large dataset and a new method for vehicle re-identification in the wild,” en,
- [19] S. He, H. Luo, P. Wang, F. Wang, H. Li, and W. Jiang, “Transreid: Transformer-based object re-identification,” in *2021 IEEE/CVF International Conference on Computer Vision (ICCV)*, Montreal, QC, Canada: IEEE, Oct. 2021, pp. 14 993–15 002, ISBN: 978-1-6654-2812-5. DOI: 10.1109/ICCV48922.2021.01474 address: <https://ieeexplore.ieee.org/document/9710179/>
- [20] H. Luo, Y. Gu, X. Liao, S. Lai, and W. Jiang, “Bag of tricks and a strong baseline for deep person re-identification,” 2019. DOI: 10.48550/ARXIV.1903.07071 address: <https://arxiv.org/abs/1903.07071>
- [21] A. Kanaci, X. Zhu, and S. Gong, “Vehicle re-identification in context,” in *Pattern Recognition - 40th German Conference, GCPR 2018, Stuttgart, Germany, September 10-12, 2018, Proceedings*, 2018.
- [22] L. Wen et al., “DETRAC: A new benchmark and protocol for multi-object detection and tracking,” *arXiv CoRR*, vol. abs/1511.04136, 2015.