

VEHICLE RE-IDENTIFICATION

Đồ án môn học: Thị giác máy tính

Chung Tín Đạt MSSV: 23122024
Nguyễn Đăng Khôi MSSV: 23122037

Giảng viên hướng dẫn:
TS. Võ Hoài Việt
ThS. Phạm Minh Hoàng
Khoa Công nghệ Thông tin
Trường Đại học Khoa học Tự nhiên

Ngày 5 tháng 6 năm 2026



Mục lục

- 1 Giới thiệu
- 2 Phát biểu bài toán
- 3 Phương pháp đề xuất
- 4 Thử nghiệm
- 5 Phân tích và đánh giá
- 6 Kết luận và hướng phát triển



Mục lục

- 1 Giới thiệu
 - Bối cảnh
 - Động lực nghiên cứu
- 2 Phát biểu bài toán
- 3 Phương pháp đề xuất
- 4 Thử nghiệm
- 5 Phân tích và đánh giá
- 6 Kết luận và hướng phát triển



Giới thiệu: Bối cảnh

Trong những năm gần đây, sự bùng nổ của hạ tầng giao thông đô thị cùng với việc triển khai rộng rãi hệ thống Giao thông Thông minh (Intelligent Transportation Systems - ITS) đã dẫn đến sự tích hợp mạnh mẽ của mạng lưới camera giám sát diện rộng.

- Số lượng phương tiện tăng nhanh.
- Hệ thống giám sát sử dụng camera ngày càng phổ biến.
- Đô thị thông minh (smart city) ngày càng phát triển mạnh

Trong bối cảnh đó, bài toán Tái định danh Phương tiện (Vehicle Re-Identification - Vehicle ReID) được đề xuất nhằm tập trung vào việc xác định xem một phương tiện mục tiêu đã từng xuất hiện ở một camera cụ thể có tái xuất hiện tại các vị trí camera khác trong cùng một hệ thống giám sát có vùng quan sát không giao thoa hay không.



Các ứng dụng của Vehicle ReID:

- **Giám sát giao thông thông minh:** Các thành phố lớn có hàng nghìn camera, nhiều tuyến đường với lưu lượng xe lưu thông cực lớn mỗi ngày. Con người gần như không thể giám sát, theo vết thủ công từng phương tiện trên quy mô lớn. Vehicle ReID giúp hệ thống nhận diện nhanh chóng một phương tiện qua nhiều camera, giúp xây dựng lộ trình di chuyển và tối ưu hoá mật độ giao thông.
- **Hỗ trợ an ninh và điều tra:** Trong quá trình truy vết phương tiện khả nghi lưu thông trên đường, khi một camera phát hiện đối tượng, hệ thống có thể nhanh chóng tìm phương tiện đó trong hệ thống camera giao thông, bãi giữ xe, khu dân cư, đường cao tốc, giúp giảm thời gian tìm kiếm thủ công.



Các ứng dụng của Vehicle ReID:

- **Phát triển đô thị thông minh:** Vehicle ReID hỗ trợ quản lý bãi đỗ xe thông minh, thu phí tự động theo thời gian, tối ưu đèn giao thông, phát hiện hành vi vi phạm giao thông.



Giới thiệu: Động lực nghiên cứu

Vehicle ReID là bài toán cần sự phối hợp của nhiều camera để xác định ảnh chụp từ các camera khác nhau có phải cùng một phương tiện hay không. Tuy nhiên trong thực tế, hệ thống camera thường được đặt ở nhiều vị trí khác nhau, dẫn đến ảnh chụp có thể bị lệch và không có vùng nhìn chồng lấp, do đó không thể chỉ dùng các phương pháp truy vết thông thường.

Mặc dù chia sẻ một số kỹ thuật nền tảng với bài toán phân loại ảnh truyền thống, Vehicle ReID sở hữu những đặc thù kỹ thuật phức tạp và thách thức hơn. Đối với phân loại ảnh thông thường, nhãn lớp ở giai đoạn kiểm thử hoàn toàn nằm trong tập danh mục đã biết trước khi huấn luyện. Ngược lại, thách thức cốt lõi của Vehicle ReID nằm ở việc định danh (ID) của các phương tiện trong tập kiểm thử hoàn toàn tách biệt và chưa từng xuất hiện trong quá trình huấn luyện.



Giới thiệu: Động lực nghiên cứu

Các khó khăn chính của Vehicle ReID:

- **Sự khác biệt trong nội bộ lớp (Intra-class Variance):** Cùng một xe nhưng khi quan sát từ các hướng: phía trước, phía sau, bên hông sẽ cho ra hình ảnh rất khác nhau.
- **Sự tương đồng giữa các lớp (Inter-class Similarity):** Các xe do cùng hãng, cùng màu, cùng kiểu dáng, cùng thiết kế, ... khiến cho hệ thống dễ bị nhầm lẫn.
- **Điều kiện môi trường và cơ sở hạ tầng:** Do hệ thống camera thường đặt bên ngoài đường phố, các điều kiện thời tiết như ánh sáng, ngày/đêm, mưa, độ phân giải thấp, che khuất giữa các phương tiện yêu cầu hệ thống phải có khả năng trích xuất đặc trưng một cách hợp lý.



Mục lục

- 1 Giới thiệu
- 2 **Phát biểu bài toán**
 - Quy trình hoạt động tổng quát
 - Các giai đoạn xử lý
- 3 Phương pháp đề xuất
- 4 Thử nghiệm
- 5 Phân tích và đánh giá
- 6 Kết luận và hướng phát triển



Phát biểu bài toán

Bài toán Vehicle Re-Identification (Vehicle ReID) là bài toán truy xuất phương tiện, với mục tiêu xác định xem các ảnh chụp từ nhiều camera khác nhau có thuộc cùng một phương tiện hay không.

- **Đầu vào:** Bài toán nhận một ảnh truy vấn I_q chứa phương tiện cần tìm kiếm và một tập ảnh thư viện (gallery) $G = \{I_1, I_2, \dots, I_N\}$ gồm các ảnh phương tiện được thu thập từ nhiều camera khác nhau. Trong giai đoạn huấn luyện, mỗi ảnh I_k được gán nhãn định danh phương tiện L_k .
- **Đầu ra:** Danh sách các ảnh trong gallery được sắp xếp theo mức độ tương đồng với ảnh truy vấn I_q , ưu tiên các kết quả được ghi nhận từ những camera khác. Các ảnh có khả năng thuộc cùng ID với ảnh truy vấn sẽ có độ tương đồng cao hơn và được xếp ở các vị trí đầu trong danh sách Rank- k . Trong quá trình đánh giá, các ảnh có cùng ID phương tiện và cùng ID camera với ảnh truy vấn được loại bỏ vì không phản ánh đúng khả năng truy xuất cross-camera.



Phát biểu bài toán

Mục tiêu của Vehicle ReID là học một hàm trích xuất đặc trưng $f(\cdot; \theta)$, trong đó θ là tập tham số của mô hình. Với một ảnh đầu vào I , hàm f ánh xạ ảnh này thành vector đặc trưng $E = f(I; \theta)$ trong không gian đặc trưng. Mức độ tương đồng giữa ảnh truy vấn p và ảnh gallery g được xác định dựa trên hai vector đặc trưng tương ứng:

$$\text{Sim}(p, g) = d(f(p, \theta), f(g, \theta))$$

trong đó $d(\cdot, \cdot)$ là một độ đo tương đồng hoặc khoảng cách trong không gian đặc trưng.



Phát biểu bài toán

Mục tiêu tối ưu có thể được biểu diễn như sau:

$$\theta^* = \arg \min_{\theta} \sum_{k=1}^N \mathbb{E}(f(I_k; \theta), L_k)$$

trong đó, $\mathbb{E}$ là hàm mất mát tổng quát dùng để huấn luyện mô hình. Hàm mất mát này thường kết hợp giữa thành phần học phân loại và thành phần học khoảng cách:

$$\mathbb{E} = \lambda_1 L_C + \lambda_2 L_M,$$

trong đó L_C là mất mát phân loại (classification loss) dùng để phân loại ID phương tiện; L_M là mất mát độ đo (metric loss) nhằm tăng khả năng tách biệt giữa các phương tiện trong không gian đặc trưng; λ_1, λ_2 là trọng số đóng góp tương ứng của từng mất mát.



Phát biểu bài toán: Quy trình hoạt động tổng quát

- 1 Tiếp nhận ảnh phương tiện: Ảnh thu được từ camera được đưa vào hệ thống phát hiện đối tượng để xác định vị trí phương tiện trong khung hình và cắt vùng ảnh tương ứng.
- 2 Trích xuất đặc trưng: Ảnh phương tiện sau khi được cắt được đưa vào mô hình trích xuất đặc trưng để sinh ra vector đặc trưng. Các vector đặc trưng của cùng một phương tiện được kỳ vọng nằm gần nhau trong không gian đặc trưng, ngược lại, các vector của những phương tiện khác nhau nằm cách xa nhau.
- 3 So sánh đặc trưng: Vector đặc trưng của ảnh truy vấn được so sánh với các vector đặc trưng trong gallery, được tạo ra tương tự ở bước 2.
- 4 Truy vấn và xếp hạng: Dựa trên độ đo tương đồng, hệ thống sắp xếp các ảnh trong gallery và trả về những kết quả có khả năng thuộc cùng phương tiện với ảnh truy vấn.



Phát biểu bài toán: Các giai đoạn xử lý

❶ **Giai đoạn 1:** Huấn luyện mô hình với tập dữ liệu đã được crop và xây dựng cơ sở dữ liệu đặc trưng:

- ❶ Huấn luyện mô hình: Hàm trích xuất đặc trưng $f(\cdot; \theta)$ được huấn luyện trên tập dữ liệu có nhãn nhằm tối ưu hàm mất mát $\mathbb{E}$.
- ❷ Xây dựng cơ sở dữ liệu gallery sau huấn luyện: Toàn bộ ảnh gallery được đưa vào mô hình, các vector đặc trưng được lưu lại để phục vụ quá trình truy vấn.

$$G = \{E_1, E_2, \dots, E_N\}$$

trong đó N là số ảnh trong gallery, $E_i = f(I_i, \theta)$.



Phát biểu bài toán: Các giai đoạn xử lý

② **Giai đoạn 2:** Truy xuất phương tiện từ ảnh truy vấn:

- ① Sinh vector đặc trưng bằng cách đưa ảnh truy vấn vào mô hình.

$$E_q = f(I_q, \theta)$$

- ② So sánh với toàn bộ embedding trong gallery bằng độ đo tương đồng.

$$\text{Sim}(E_q, E_i) = d(E_q, E_i)$$

trong đó E_i là embedding của ảnh thứ i trong gallery.

- ③ Hệ thống sắp xếp kết quả truy vấn theo độ tương đồng giảm dần và xuất kết quả.

$$R = \text{sort}(\text{sim}(E_q, E_i))$$




Mục lục

- 1 Giới thiệu
- 2 Phát biểu bài toán
- 3 Phương pháp đề xuất**
 - Kiến trúc mô hình
 - Hàm mất mát
- 4 Thử nghiệm
- 5 Phân tích và đánh giá
- 6 Kết luận và hướng phát triển



Phương pháp đề xuất: Kiến trúc mô hình

Nhóm sử dụng mô hình ResNet50 được tiền huấn luyện trên tập dữ liệu ImageNetV2 làm backbone cho hệ thống Vehicle ReID. Việc tận dụng trọng số đã được học từ ImageNet giúp mô hình khai thác hiệu quả các đặc trưng thị giác tổng quát. Mô hình được kết hợp với cơ chế chú ý cục bộ của Convolutional Block Attention Module và các kĩ thuật của Bag of Tricks để tối ưu hóa không gian đặc trưng.



Hình 1: Kiến trúc tổng thể của hệ thống Vehicle ReID được đề xuất



Backbone ResNet50 và Last Stride Modification

Để phù hợp với bài toán Vehicle ReID đòi hỏi bảo toàn thông tin không gian ở các layer sâu, tham số stride của khối tích chập cuối cùng được điều chỉnh từ 2 xuống 1. Với ảnh đầu vào kích thước 256×256 , điều chỉnh này giúp giữ lại feature map có độ phân giải không gian cao hơn (từ 8×8 tăng lên 16×16), hạn chế sự mất mát các fine-grained đặc trưng cục bộ quan trọng như hình dáng đèn xe, logo, biển số hoặc đường nét thân xe.



Phương pháp đề xuất: Kiến trúc mô hình

Convolutional Block Attention Module

Để tăng cường khả năng trích xuất các đặc trưng có tính phân biệt cao và giảm thiểu ảnh hưởng của nhiễu môi trường, mô-đun CBAM được tích hợp vào sau các khối tích chập của mạng ResNet50.

Đầu tiên, feature map đầu vào $F \in \mathbb{R}^{C \times H \times W}$ được xử lý qua Channel Attention Module để xác định các đặc trưng kênh quan trọng thông qua việc kết hợp Average Pooling và Max Pooling.

$$M_c(F) = \sigma(\text{MLP}(\text{AvgPool}(F)) + \text{MLP}(\text{MaxPool}(F)))$$
$$F' = M_c(F) \otimes F$$

Sau đó, bản đồ đặc trưng F' được đưa qua Spatial Attention Module để xác định các vị trí hình học chứa thông tin định danh bằng cách áp dụng tích chập để tạo ra feature map cuối cùng.

$$M_s(F') = \sigma(f^{7 \times 7}([\text{AvgPool}(F'); \text{MaxPool}(F')]))$$
$$F'' = M_s(F') \otimes F'$$



Phương pháp đề xuất: Kiến trúc mô hình

Global Average Pooling và Cấu trúc BNNeck

Sau khi đi qua module chú ý, feature map được đưa qua lớp Global Average Pooling (GAP) để tổng hợp thông tin không gian thành một vector đặc trưng toàn cục $z = GAP(F'')$.

Để giải quyết sự xung đột về không gian tối ưu giữa hàm loss phân loại và hàm loss khoảng cách, cấu trúc BNNeck (Batch Normalization Neck) được triển khai ngay sau lớp GAP. Vector đặc trưng thô z được sử dụng trực tiếp để tính toán Triplet Loss nhằm tối ưu hóa khoảng cách Cosine. Đồng thời, z được đưa qua một layer Batch Normalization để tạo ra vector đặc trưng chuẩn hóa z_n . Vector z_n này được kết nối với Classifier Head để dự đoán ID phương tiện và tính toán ID Loss trong giai đoạn huấn luyện.



Phương pháp đề xuất: Hàm mất mát

Nhóm sử dụng kết hợp hai hàm mất mát nhằm tối ưu đồng thời khả năng phân loại và khả năng học không gian đặc trưng cho bài toán Vehicle ReID:

- **ID Loss (Cross Entropy kết hợp Label Smoothing):** Thay vì sử dụng nhãn one-hot tuyệt đối, kỹ thuật Label Smoothing phân phối một phần nhỏ xác suất sang các lớp khác, giúp mô hình giảm hiện tượng overconfident đối với dữ liệu huấn luyện. Nhờ đó, vector đặc trưng học được có khả năng tổng quát hóa tốt hơn đối với các phương tiện chưa xuất hiện trong tập kiểm thử.
- **Triplet Loss:** Hàm mất mát này có nhiệm vụ tối ưu khoảng cách trong không gian embedding. Điều này giúp các embedding của cùng một xe nằm gần nhau, trong khi embedding của các xe khác nhau được tách biệt rõ ràng hơn trong không gian đặc trưng.



Mục lục

- 1 Giới thiệu
- 2 Phát biểu bài toán
- 3 Phương pháp đề xuất
- 4 Thử nghiệm**
 - Dữ liệu và độ đo đánh giá
 - Chi tiết cài đặt
- 5 Phân tích và đánh giá
- 6 Kết luận và hướng phát triển



Thử nghiệm: Dữ liệu và độ đo đánh giá

VeRi-776¹ chứa hơn **50000** hình ảnh của **776** ID xe khác nhau. Dữ liệu được ghi hình từ mạng lưới **20** camera giám sát đặt tại các góc giao lộ thực tế.

VRIC² là tập hợp 5622 xe được thu thập 24 khu vực, bao gồm 60430 ảnh có điều kiện môi trường đa dạng.

¹<https://www.kaggle.com/datasets/abhyudaya12/veri-vehicle-re-identification-dataset>

²<https://qmul-vric.github.io/>

Thử nghiệm: Dữ liệu và độ đo đánh giá

Cụ thể, số lượng mẫu được chia trong từng tập như sau:

- **VeRi776**: tổng cộng **51035** ảnh.
 - Tập huấn luyện: **37778** ảnh của **500** ID phương tiện.
 - Tập kiểm thử: **11579** ảnh gallery, **1678** ảnh truy vấn và **276** ID phương tiện.
- **VRIC**: tổng cộng **60430** ảnh.
 - Tập huấn luyện: **54808** ảnh của **2811** ID phương tiện.
 - Tập kiểm thử: **2811** ảnh gallery, **2811** ảnh truy vấn và **2811** ID phương tiện.



Thử nghiệm: Dữ liệu và độ đo đánh giá

Nhóm sử dụng hai độ đo mAP (mean Average Precision) và CMC@ k (Cumulative Matching Characteristic at rank k) để đánh giá hiệu suất truy xuất của mô hình. Trong quá trình đánh giá, các ảnh trong gallery có đồng thời ID phương tiện và ID camera trùng với ảnh truy vấn được xem là ảnh rác (junk images) và bị loại khỏi danh sách xếp hạng, vì chúng không phản ánh đúng khả năng truy xuất cross-camera của mô hình.



Thử nghiệm: Dữ liệu và độ đo đánh giá

① Cumulative Matching Characteristics (CMC Curve / Độ chính xác Rank-k):

- Đo lường "tính khả dụng" của hệ thống. Đây là xác suất để chiếc xe cần tìm (True Match) xuất hiện trong tập hợp k kết quả trả về đầu tiên.
- Nếu hệ thống có Rank-5 cao, nghĩa là người vận hành (ví dụ: cảnh sát giao thông) chỉ cần kiểm tra 5 ảnh đầu tiên là gần như chắc chắn tìm thấy phương tiện nghi vấn.

② Mean Average Precision (mAP):

- Đo lường "độ toàn diện" của mô hình. Một ID xe có thể bị chụp bởi 10 camera khác nhau. Rank-1 chỉ yêu cầu tìm thấy 1 ảnh đúng đầu tiên, nhưng mAP yêu cầu mô hình phải kéo toàn bộ 10 ảnh đó lên các thứ hạng cao nhất.
- mAP phản ánh độ mạnh của hệ thống trước sự biến thiên nội lớp (Intra-class Variance) như đổi góc chụp hay thay đổi ánh sáng.



Thử nghiệm: Chi tiết cài đặt

Thử nghiệm được thực hiện trên nền tảng Kaggle với GPU T4 x2. Mô hình được cài đặt bằng Python 3.12 và PyTorch 2.10. Nhóm sử dụng ResNet50 được tiền huấn luyện trên ImageNetV2 làm backbone để trích xuất đặc trưng. Các mô hình được huấn luyện trên tập VeRi776 và đánh giá trên VeRi776 và VRIC nhằm kiểm tra khả năng truy xuất trong cùng miền dữ liệu và khác miền dữ liệu.



Thử nghiệm: Chi tiết cài đặt

Tất cả ảnh đầu vào được thay đổi kích thước về 256×256 và chuẩn hóa theo phân phối của ImageNetV2. Trong quá trình huấn luyện, nhóm áp dụng các kỹ thuật tăng cường dữ liệu gồm lật ngang ngẫu nhiên, điều chỉnh độ sáng, biến đổi affine. Đối với các cấu hình sử dụng Bag of Tricks (BOT), kỹ thuật xóa vùng ngẫu nhiên (random erasing) được bổ sung.



Thử nghiệm: Chi tiết cài đặt

Cấu hình hyperparameter chung được thiết lập như sau:

- **Optimizer:** AdamW với weight decay bằng 5×10^{-4} .
- **Batch size:** 32 ảnh. Mỗi batch được lấy mẫu theo ID, trong đó mỗi ID có 8 ảnh để hỗ trợ việc tính toán metric loss.
- **Learning rate:** Learning rate của các lớp mới là 3×10^{-4} , trong khi learning rate của backbone được đặt ở 3×10^{-5} .
- **Scheduler:** Cosine Annealing được sử dụng để giảm learning rate trong quá trình huấn luyện; với các cấu hình BOT, nhóm bổ sung Linear Warmup Scheduler trong 10 epoch đầu, với learning rate nhỏ nhất là 1×10^{-5} .
- **Số epoch:** Mỗi mô hình được huấn luyện trong 60 epoch.
- **Embedding dimension:** Vector đặc trưng đầu ra có số chiều là 2048.
- **Loss function:** Hàm mất mát gồm thành phần phân loại và độ đo; metric loss sử dụng biên bằng 0.3. Trọng số đóng góp của mỗi mất mát là như nhau $\lambda_1 = \lambda_2 = 1$.



Thử nghiệm: Chi tiết cài đặt

Nhóm xây dựng và so sánh bốn cấu hình mô hình. Cấu hình Baseline gồm backbone ResNet50, lớp Global Average Pooling (GAP), embedding layer và classifier head. Với cấu hình CBAM, mô-đun CBAM được đặt ở cuối các major block của ResNet50. Với cấu hình BOT, nhóm bổ sung Batch Normalization sau lớp GAP, thay đổi stride ở major block cuối của ResNet50, label smoothing, random erasing và warmup learning rate.

Bảng 1: Thông số cài đặt riêng của từng mô hình

Mô hình	Warmup	Warmup LR	Random erase	Label smoothing	Last stride
Baseline	0	-	Không	Không	2
+ BOT	10	1×10^{-5}	Có	Có	1
+ CBAM	0	-	Không	Không	2
+ BOT + CBAM	10	1×10^{-5}	Có	Có	1



Thử nghiệm: Chi tiết cài đặt

Để đánh giá hiệu quả triển khai, nhóm so sánh các mô hình tự xây dựng với ReID Strong Baseline (ReIDSB) được huấn luyện trên VeRi776.

Bảng 2: So sánh kết quả định lượng trên hai tập dữ liệu VeRi776 và VRIC

Mô hình	VeRi776				VRIC			
	mAP	Rank-1	Rank-5	Rank-10	mAP	Rank-1	Rank-5	Rank-10
Baseline	64.34%	89.87%	95.35%	97.08%	17.90%	11.38%	23.66%	30.31%
+ BOT	66.10%	91.90%	96.72%	98.09%	23.20%	16.61%	29.14%	35.72%
+ CBAM	61.58%	88.80%	94.34%	96.66%	18.45%	12.20%	23.44%	30.27%
+ BOT + CBAM	66.00%	91.48%	96.54%	98.21%	26.71%	18.85%	34.29%	41.62%
ReIDSB	74.40%	93.30%	97.40%	98.50%	23.46%	16.47%	29.74%	37.03%



Mục lục

- 1 Giới thiệu
- 2 Phát biểu bài toán
- 3 Phương pháp đề xuất
- 4 Thử nghiệm
- 5 Phân tích và đánh giá**
 - Hiện tượng suy giảm đặc trưng không gian
 - Hiện tượng trùng mẫu xe
 - Mật độ phân phối độ tương đồng
 - Cross-Dataset Domain Shift Analysis
 - Minh họa kết quả truy xuất
- 6 Kết luận và hướng phát triển



Phân tích và đánh giá: Hiện tượng suy giảm đặc trưng không gian



Hình 2: Các trường hợp false match (viền đỏ) do mất mát chi tiết không gian

Phân tích và đánh giá: Hiện tượng suy giảm đặc trưng không gian

Quan sát các kết quả truy xuất ở những thứ hạng cao (Hình 2) cho thấy mô hình vẫn xuất hiện các trường hợp nhận diện sai khi ảnh truy vấn và ảnh dương sai có độ tương đồng lớn về màu sắc tổng thể và góc nhìn, mặc dù giữa chúng vẫn tồn tại các chi tiết nhận dạng khác biệt.



Phân tích và đánh giá: Hiện tượng trùng mẫu xe



Hình 3: Các trường hợp false match (viền đỏ) do cấu trúc xe đồng nhất

Phân tích và đánh giá: Hiện tượng trùng mẫu xe

Một số false positive xuất hiện khi các phương tiện khác ID có hình dáng, màu sắc và ngoại quan rất giống nhau. Trong các trường hợp này, những chi tiết có tính phân biệt cao như biển số, logo hoặc dấu hiệu riêng trên thân xe không được thể hiện đủ rõ, khiến mô hình có thể nhận diện đúng nhóm đặc điểm của xe nhưng không phân biệt chính xác ID phương tiện. Hiện tượng này thường gặp ở các phương tiện được thiết kế hoặc trang trí đồng nhất, chẳng hạn xe taxi, xe buýt hoặc xe thuộc cùng một đội vận hành (Hình 3).




Phân tích và đánh giá: Mật độ phân phối độ tương đồng


Dựa trên phân bố mật độ của độ tương đồng cosine trong Hình 4 và Hình 5, có thể thấy mô hình đã học được khả năng phân tách cơ bản giữa các cặp ảnh cùng ID và khác ID.




Phân tích và đánh giá: Mật độ phân phối độ tương đồng - VeRi776




(a) Baseline



(b) BOT



(c) CBAM




(d) BOT + CBAM


Hình 4: Biểu đồ phân bố mật độ (KDE) của độ đo tương đồng cosine trên VeRi776




Phân tích và đánh giá: Mật độ phân phối độ tương đồng - VRIC




(a) Baseline



(b) BOT



(c) CBAM



(d) BOT + CBAM

Hình 5: Biểu đồ phân bố mật độ (KDE) của độ đo tương đồng cosine trên VRIC

Phân tích và đánh giá: Cross-Dataset Domain Shift Analysis

Kết quả thực nghiệm cho thấy các chỉ số hiệu suất đều suy giảm đáng kể khi mô hình được huấn luyện trên miền nguồn VeRi-776 và đánh giá trên miền đích VRIC, chi tiết trong Bảng 3.



Phân tích và đánh giá: Cross-Dataset Domain Shift Analysis - Bảng đối chiếu

Bảng 3: Mức độ sụt giảm hiệu suất giữa VeRi-776 và VRIC

Cấu hình	Chỉ số	VeRi-776	VRIC	Sụt giảm
ReIDSB	mAP	74.40%	23.46%	−50.94%
ReIDSB	Rank-1	93.30%	16.47%	−76.83%
ReIDSB	Rank-5	97.40%	29.74%	−67.66%
ReIDSB	Rank-10	98.50%	37.03%	−61.47%
BOT + CBAM	mAP	66.00%	26.71%	−39.29%
BOT + CBAM	Rank-1	91.48%	18.85%	−72.63%
BOT + CBAM	Rank-5	96.54%	34.29%	−62.25%
BOT + CBAM	Rank-10	98.21%	41.62%	−56.59%

Phân tích và đánh giá: Cross-Dataset Domain Shift Analysis - Nguyễn nhân

Sự suy giảm hiệu năng trên VRIC chủ yếu đến từ:

- **Domain shift:** VRIC có góc camera cao, độ phân giải thấp và điều kiện chiếu sáng phức tạp hơn VeRi-776.
- **Hard negatives:** Nhiều xe khác ID có màu sắc và kiểu dáng tương tự, khiến mô hình dễ phụ thuộc vào đặc trưng toàn cục.
- **Aspect ratio mismatch:** Resize về 256×256 có thể làm biến dạng chi tiết cục bộ, đặc biệt với ảnh góc nhìn từ trên xuống.



Phân tích và đánh giá: Minh họa kết quả truy xuất


Bên cạnh các chỉ số định lượng, nhóm minh họa kết quả truy xuất của bốn cấu hình mô hình trên VeRi776 và VRIC. Trong mỗi nhóm, thứ tự từ trên xuống lần lượt là Baseline, CBAM, BOT và BOT + CBAM.



Phân tích và đánh giá: Minh họa kết quả truy xuất - VeRi776, truy vấn 1



Phân tích và đánh giá: Minh họa kết quả truy xuất - VeRi776, truy vấn 2



Phân tích và đánh giá: Minh họa kết quả truy xuất - VeRi776, truy vấn 3



Phân tích và đánh giá: Minh họa kết quả truy xuất - VRIC, truy vấn 1



Phân tích và đánh giá: Minh họa kết quả truy xuất - VRIC, truy vấn 2



Mục lục

- 1 Giới thiệu
- 2 Phát biểu bài toán
- 3 Phương pháp đề xuất
- 4 Thử nghiệm
- 5 Phân tích và đánh giá
- 6 Kết luận và hướng phát triển**
 - Kết luận
 - Hướng phát triển



Kết luận và hướng phát triển: Kết luận

Báo cáo đã xây dựng và kiểm chứng một hệ thống Vehicle ReID dựa trên backbone ResNet50, kết hợp các thành phần tối ưu như BNNeck, hàm mất mát đa mục tiêu, CBAM và các kỹ thuật BOT. Hệ thống được đánh giá trên hai tập dữ liệu VeRi776 và VRIC nhằm khảo sát hiệu quả trong cùng miền dữ liệu cũng như khả năng tổng quát hóa sang miền dữ liệu khác. Trên VeRi776, các cấu hình có BOT đạt kết quả tốt hơn Baseline, với mAP khoảng 66% và Rank-1 trên 91%. Điều này cho thấy các kỹ thuật như random erasing, label smoothing, warmup learning rate và điều chỉnh last stride có đóng góp tích cực vào khả năng phân tách đặc trưng và cải thiện thứ tự truy xuất. Trên VRIC, cấu hình kết hợp BOT và CBAM đạt kết quả cao hơn rõ rệt so với ReIDSB, qua đó khẳng định hiệu quả của các cải tiến được đề xuất.



Kết luận và hướng phát triển: Kết luận

Qua việc phân tích các trường hợp false match, báo cáo chỉ ra hai nguyên nhân chính gây lỗi: mất mát chi tiết không gian sau quá trình tổng hợp đặc trưng toàn cục và sự tương đồng ngoại quan cao giữa các phương tiện khác ID. Những lỗi này khó xử lý khi các chi tiết phân biệt như biển số, logo, đèn xe hoặc dấu hiệu riêng trên thân xe không đủ rõ. Do đó, mặc dù hệ thống đã đạt được hiệu quả truy xuất cơ bản và cho thấy lợi ích của BOT và CBAM trong bài toán đề ra, mô hình hiện tại vẫn còn hạn chế trong các tình huống dương khó, âm khó và triển khai trên môi trường camera thực tế có biến thiên lớn.



Kết luận và hướng phát triển: Hướng phát triển

Thứ nhất, hệ thống cần có cơ chế xếp hạng lại (re-ranking). Kết quả thực nghiệm cho thấy vẫn tồn tại khoảng cách đáng kể giữa mAP và các chỉ số Rank- k cũng như giữa Rank-1 và Rank-5, Rank-10, nghĩa là mô hình có thể đưa một số ảnh đúng ID lên thứ hạng cao nhưng chưa sắp xếp tối ưu toàn bộ các mẫu đúng trong danh sách truy xuất. Hướng tiếp cận này có khả năng cải thiện mAP, Rank- k và làm cho danh sách truy xuất ổn định hơn trong các trường hợp truy vấn khó.



Kết luận và hướng phát triển: Hướng phát triển

Thứ hai, hệ thống có thể khai thác thêm metadata như camera ID, vị trí camera, khoảng cách địa lý và thời điểm ghi nhận. Ví dụ, một kết quả truy xuất có thể bị giảm độ tin cậy nếu phương tiện xuất hiện tại hai camera cách xa nhau trong một khoảng thời gian không hợp lý. Việc kết hợp đặc trưng hình ảnh với các ràng buộc không-thời gian sẽ giúp loại bỏ một phần các kết quả phi logic và giảm tỷ lệ dương sai do tương đồng liên lớp gây ra.



Kết luận và hướng phát triển: Hướng phát triển

Cuối cùng, cần cải thiện khả năng bảo toàn và khai thác đặc trưng cục bộ ở tầng kiến trúc mạng. Cấu hình hiện tại vẫn phụ thuộc nhiều vào đặc trưng toàn cục sau Global Average Pooling, trong khi các chi tiết nhỏ như biển số, logo, cấu trúc đèn hoặc dấu hiệu riêng trên thân xe thường đóng vai trò quan trọng trong việc phân biệt các phương tiện có cùng ngoại quan. Do đó, các hướng sử dụng OCR, cơ chế chú ý không gian mạnh hơn hoặc kiến trúc Vision Transformer dựa trên self-attention có thể được nghiên cứu để tăng khả năng tập trung vào các vùng nhận dạng quan trọng. Những cải tiến này kỳ vọng giúp mô hình xử lý tốt hơn các mẫu dương khó, âm khó và các điều kiện quan sát phức tạp trong môi trường giao thông thực tế.

